

Machine Learning

Professor: Elton Sarmanho[1]
E-mail: eltonss@ufpa.br






[1]Faculdade de Sistemas de Informação - UFPA/CUNTINS

23 de outubro de 2026

Roteiro

Planejamento

Fundamentos de ML

Aprendizado Supervisionado

Projeto de ML

Seleção e Teste

Matriz de Confusão

Regressão

Redes Neurais

Aprendizado Não Supervisionado

Ética e Síntese

Referências



Licença

Este trabalho está licenciado sob a licença Creative Commons:





Objetivos de aprendizagem

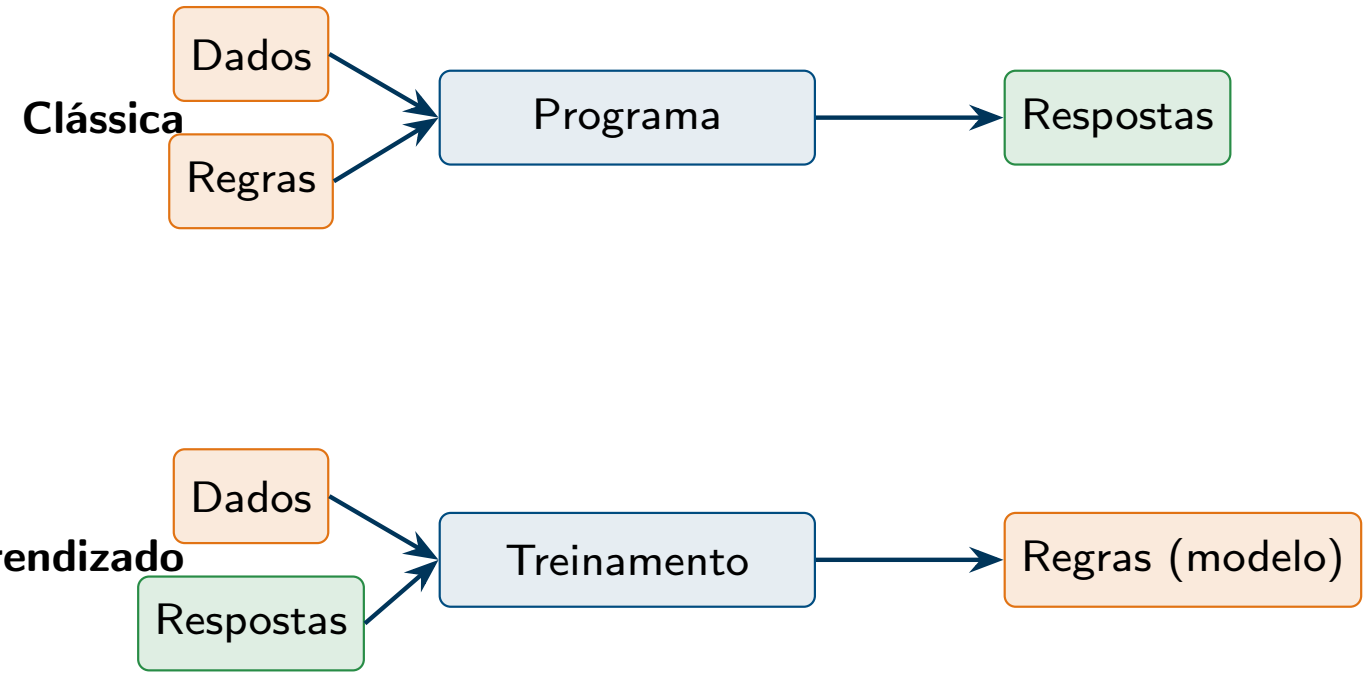
Ao final da aula, você será capaz de:

1. explicar o que é aprendizado de máquina e distinguir seus três paradigmas.
2. treinar e testar um modelo supervisionado sem vazamento de dados.
3. avaliar classificadores e regressores com as métricas adequadas.
4. descrever como uma rede neural aprende, do perceptron à retropropagação.
5. aplicar K-Means e PCA para explorar dados sem rótulos.

Códigos do livro: `https://github.com/aimacode`. Códigos do professor: GitHub.



Programar regras ou aprender com dados?



Na programação clássica, a pessoa escreve as regras. No aprendizado de máquina, o algoritmo as descobre a partir de exemplos.

O que é aprender?

Definição de Mitchell (1997)

Um programa aprende com a experiência E, em relação a uma tarefa T e a uma medida de desempenho P, se o seu desempenho em T, medido por P, melhora com E.

Exemplo: filtro de spam

- T: classificar e-mails como spam ou não spam.
- E: e-mails já rotulados por usuários.
- P: porcentagem de e-mails classificados corretamente.

A expressão *machine learning* foi popularizada por Arthur Samuel em 1959, com um programa que aprendia a jogar damas.



IA, ML e Deep Learning

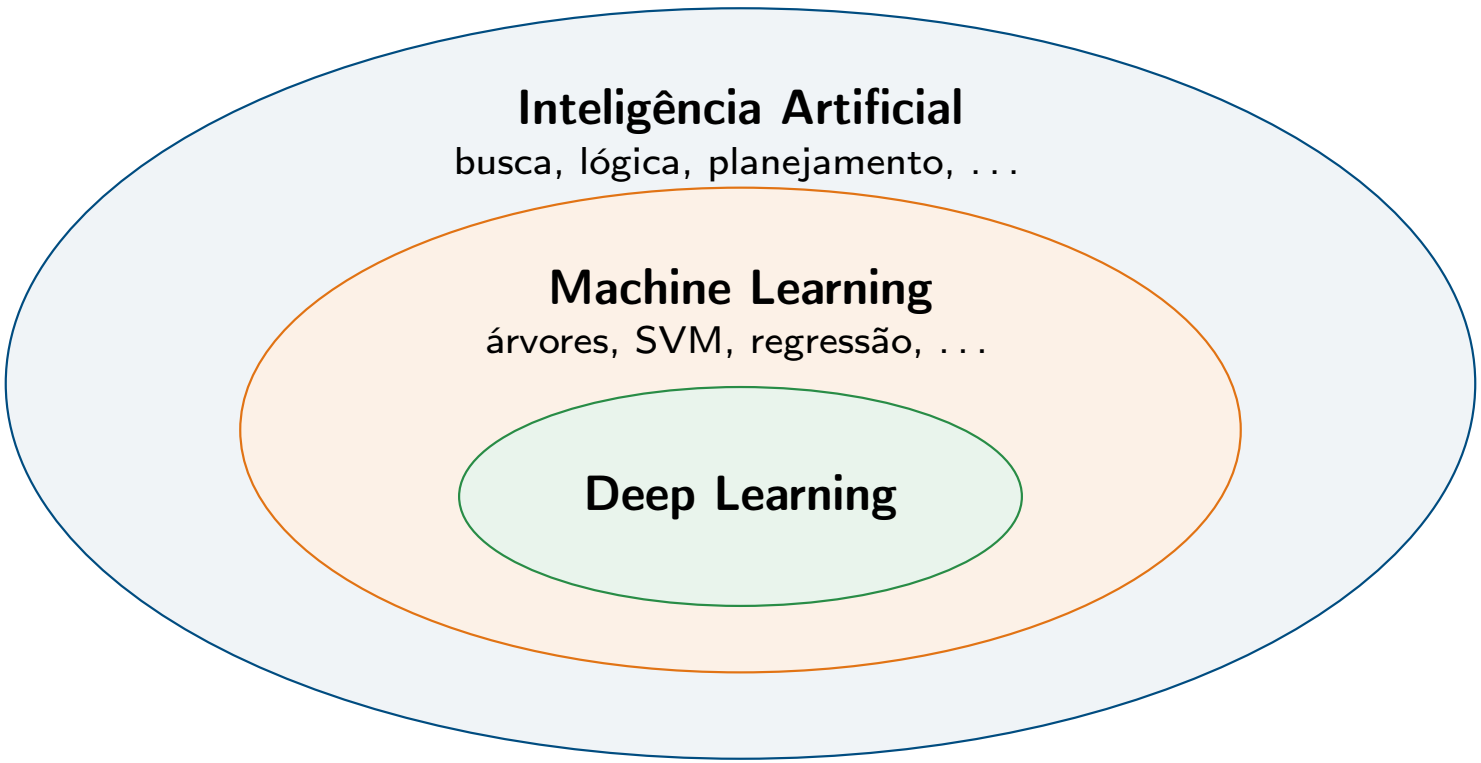
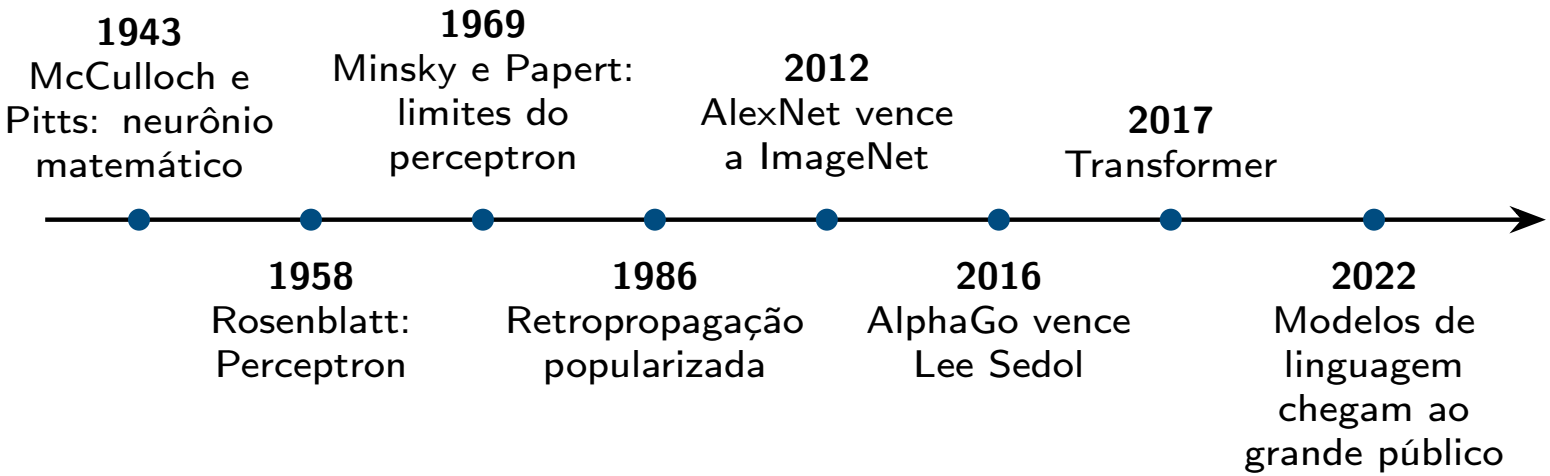


Figura: Relação entre IA, *machine learning* e *deep learning*.

Uma linha do tempo

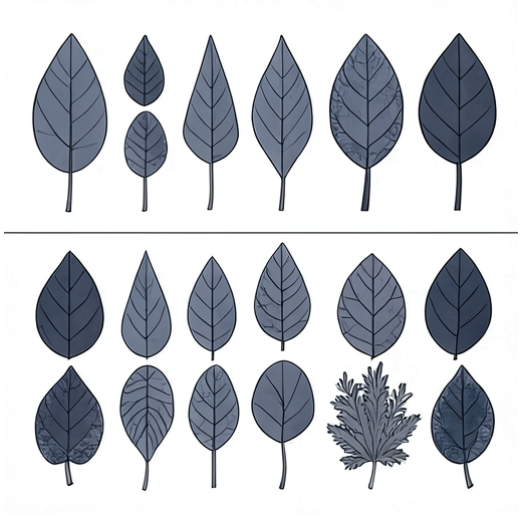


Onde o ML já está em uso

Área	**Tarefa de ML**	**Exemplo atual**
Saúde	classificar imagens médicas	triagem de retinopatia diabética
Biologia	prever estruturas	AlphaFold prevê a forma de proteínas
Linguagem	modelar texto	assistentes, tradução e geração de código
Mobilidade	perceber o ambiente	carros autônomos detectam pedestres
Finanças	detectar anomalias	fraude em cartões de crédito
Mídia	recomendar itens	Netflix e Amazon



Três formas de aprender



Supervisionado

exemplos com rótulo



Não supervisionado

estrutura sem rótulo



Por reforço

tentativa, erro e recompensa

Figura: Exemplos visuais dos três paradigmas: dados rotulados, amostras agrupadas por semelhança e um braço robótico que aprende por interação.

Comparando os paradigmas

	Supervisionado	**Não supervisionado**	**Reforço**
Dados	pares (x, y)	apenas x	interação com o ambiente
Objetivo	prever y	achar estrutura	maximizar recompensa
Exemplo	diagnóstico por imagem	segmentar clientes	robô que aprende a andar

Dilema do reforço: explorar ações novas ou aproveitar a melhor ação conhecida (*exploration vs. exploitation*). É como escolher entre um restaurante novo e o seu favorito.



Os modelos de linguagem usam qual paradigma?

- Pré-treino **autossupervisionado**: o rótulo é a próxima palavra do próprio texto.
- Ajuste fino **supervisionado** com exemplos de boas respostas.
- Alinhamento com **reforço** a partir de preferências humanas (RLHF).

? Para refletir

Por que a autossupervisão permite treinar com bilhões de textos sem rotulagem manual?



Aprendizado supervisionado

Dado um conjunto de exemplos

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^{m},$$

queremos aprender uma função h tal que $h(x) \approx y$ **também para dados novos**.

- x: atributos (*features*).
- y: rótulo ou valor alvo.
- Classificação: y é uma categoria.
- Regressão: $y \in \mathbb{R}$.

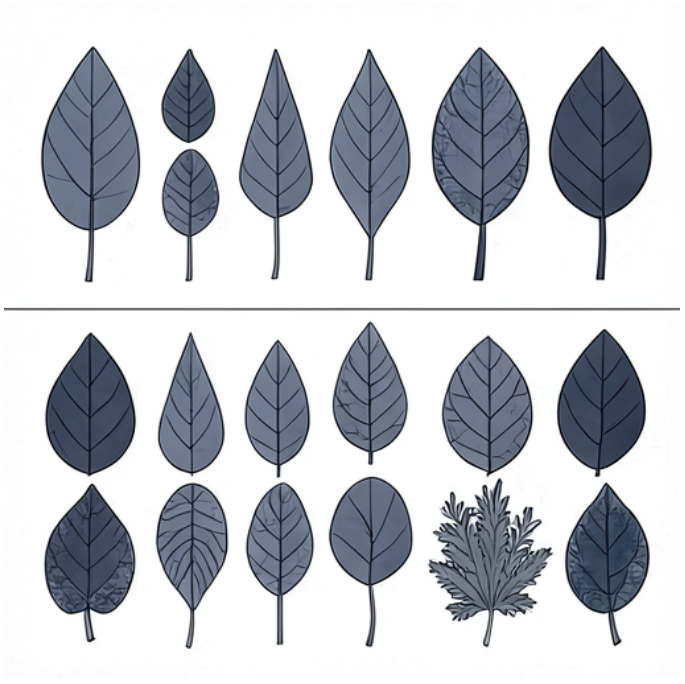


Figura: Exemplos já rotulados por espécie.

Para refletir

E se todas as folhas de uma espécie no treino vierem do mesmo jardim?

As peças do aprendizado

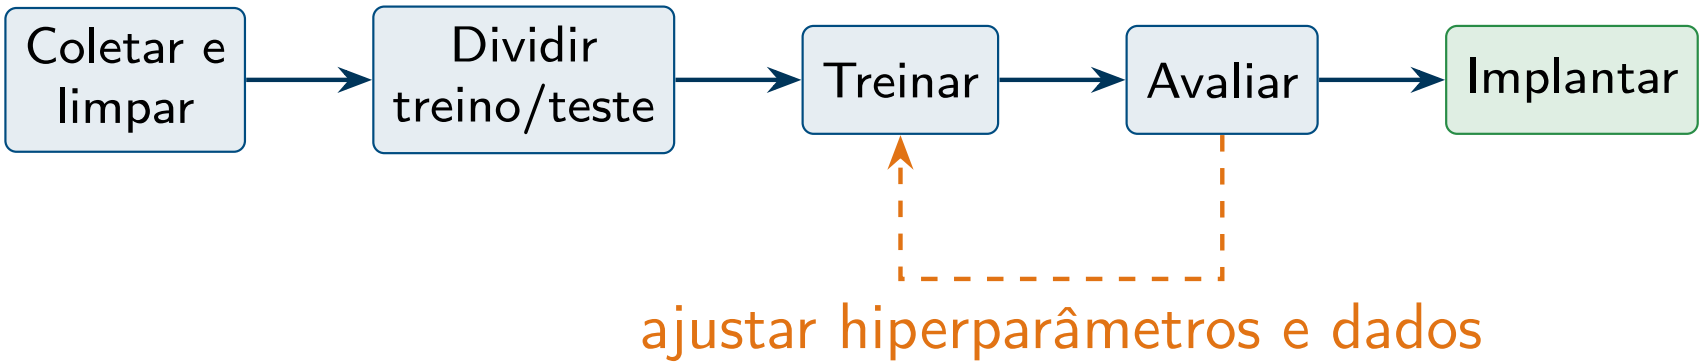
- **Modelo** h_θ: família de funções com parâmetros θ.
- **Perda** ℓ: mede o erro de uma previsão.
- **Otimização**: escolhe θ que minimiza o risco empírico

$$\hat{R}(\theta) = \frac{1}{m} \sum_{i=1}^{m} \ell\big(h_\theta(x_i), y_i\big).$$

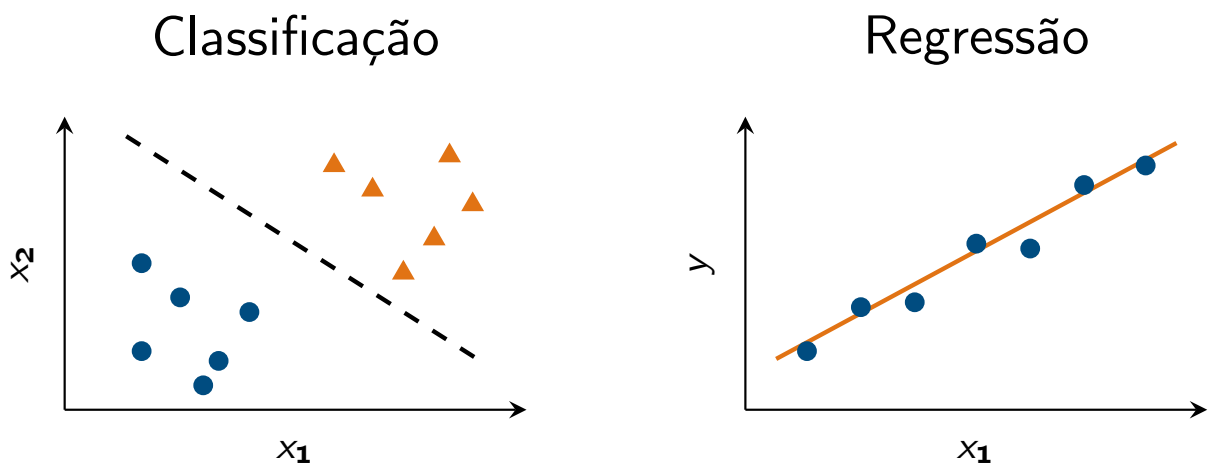
- **Avaliação**: mede o desempenho em dados que o modelo não viu.



Fluxo de trabalho

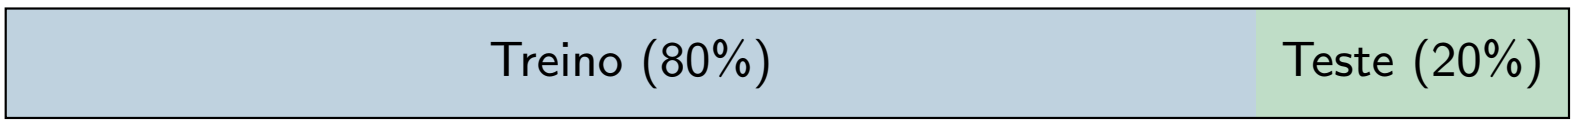


Classificação e regressão



A saída é uma **categoria** na classificação e um **número** na regressão.

Treino e teste



- **Treino**: ajusta os parâmetros.
- **Teste**: estima o desempenho final, e deve ser usado uma única vez.

Underfitting e overfitting

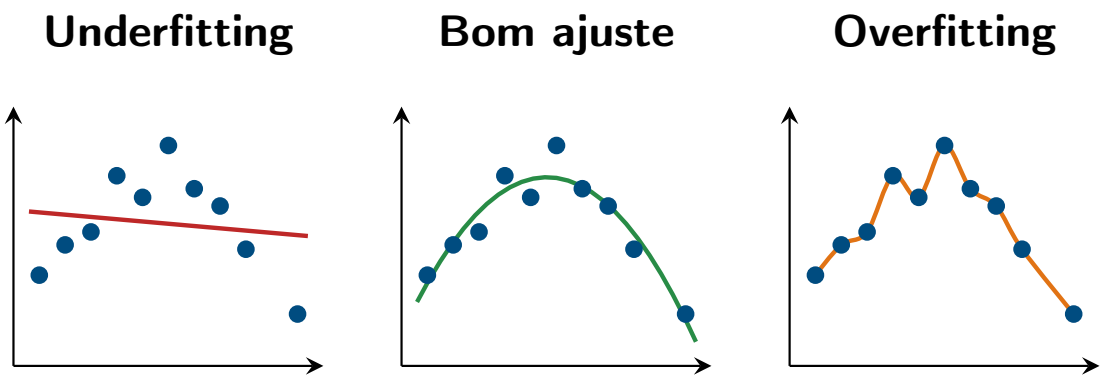


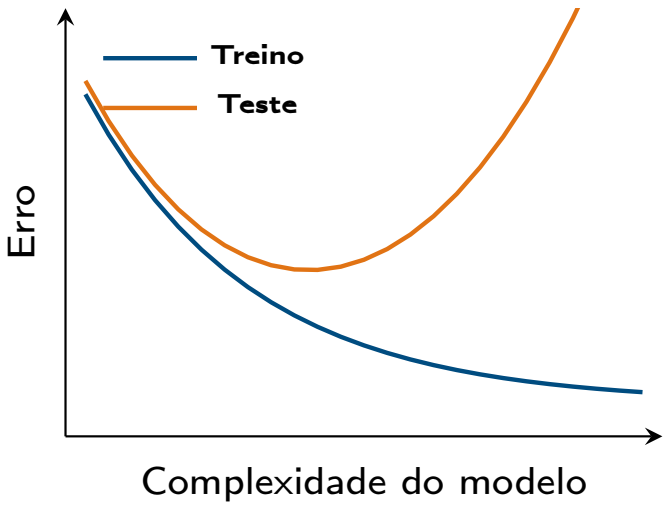
Figura: Mesmos dados, três modelos: reta, parábola e curva que passa por todos os pontos.

Como diagnosticar

Situação	**Erro treino**	**Erro teste**	**O que fazer**
Underfitting	alto	alto	modelo mais flexível, mais atributos
Bom ajuste	baixo	baixo	manter e testar
Overfitting	baixo	alto	mais dados, regularização, modelo mais simples



Viés e variância



Erro esperado com perda quadrática:

$$\text{viés}^2 + \text{variância} + \text{ruído}.$$

- Pouca complexidade: viés alto.
- Muita complexidade: variância alta.
- Buscamos o ponto intermediário.

Memorizar não é entender

Como evitar o overfitting

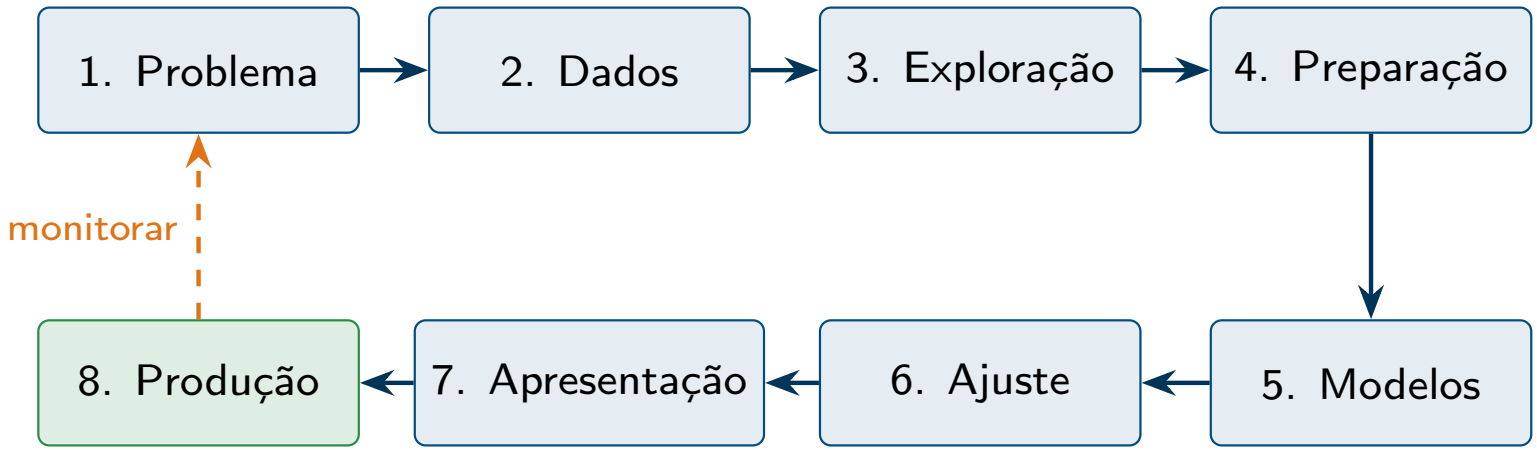
- Mais dados de boa qualidade.
- Modelo mais simples.
- Regularização.
- Cross-validation.

? Para refletir

Um aluno que decorou a prova de 2023 está preparado para a de 2024?



As oito etapas de um projeto



O processo é iterativo: a monitoração em produção gera novos dados que reiniciam o ciclo.

1. Problema e 2. Dados

Reflita sobre o problema

- Qual é o objetivo de negócio?
- Como a solução será usada?
- Como medir o sucesso?
- Existe uma linha de base simples?

Obtenha os dados

- Quais dados e em que volume?
- Há restrições legais e de privacidade?
- Separe o conjunto de teste agora e não o toque.



3. Exploração e 4. Preparação

Explore

- Trabalhe em uma cópia dos dados.
- Estude tipo, ausências e distribuição de cada atributo.
- Visualize e meça correlações.

Prepare

- Trate ausências e *outliers*.
- Codifique categorias.
- Padronize atributos numéricos.
- Escreva funções reutilizáveis.



5. Modelos, 6. Ajuste e 7. Apresentação

- Treine modelos de famílias diferentes e compare por cross-validation.
- Ajuste os hiperparâmetros dos três a cinco melhores candidatos.
- Combine modelos (*ensembles*) se houver ganho real.
- Documente suposições e limitações antes de apresentar.

Atenção

Não ajuste o modelo depois de olhar o erro no teste. Ele deixa de ser uma estimativa honesta.



8. Produção

- Conecte o modelo às fontes de dados e escreva testes.
- Monitore o desempenho com dados reais.
- Verifique a qualidade das entradas (sensores com defeito, dados antigos).
- Retreine com dados novos para acompanhar mudanças no mundo (*data drift*).



Vazamento de dados

Errado: normalizar tudo antes de dividir.

```
X = StandardScaler().
    fit_transform(X)
X_tr, X_te = train_test_split(X)
```

O teste influenciou a média e o desvio usados no treino.

Certo: aprender a transformação só no treino.

```
X_tr, X_te = train_test_split(X)
pipe = make_pipeline(
    StandardScaler(),
    LogisticRegression())
pipe.fit(X_tr, y_tr)
```



Algoritmos clássicos

Algoritmo	**Ideia**	**Ponto de atenção**
k-NN	classe dos k vizinhos mais próximos	lento com muitos dados e sensível à escala
Árvore de decisão	perguntas sucessivas sobre atributos	tende ao overfitting
Random Forest	muitas árvores votando	menos interpretável
Naive Bayes	probabilidades com atributos independentes	independência raramente vale
SVM	margem máxima entre classes	custo alto em bases grandes
Regressão logística	probabilidade por função sigmoide	fronteira linear



Exemplo completo com scikit-learn

```
from sklearn.datasets import load_breast_cancer
from sklearn.model_selection import train_test_split, GridSearchCV
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import classification_report

X, y = load_breast_cancer(return_X_y=True)
X_tr, X_te, y_tr, y_te = train_test_split(
    X, y, test_size=0.2, stratify=y, random_state=42)

pipe = make_pipeline(StandardScaler(),
                     LogisticRegression(max_iter=1000))
grid = GridSearchCV(
    pipe, {"logisticregression__C": [0.01, 0.1, 1, 10]}, cv=5)
grid.fit(X_tr, y_tr)
print(classification_report(y_te, grid.predict(X_te)))
```



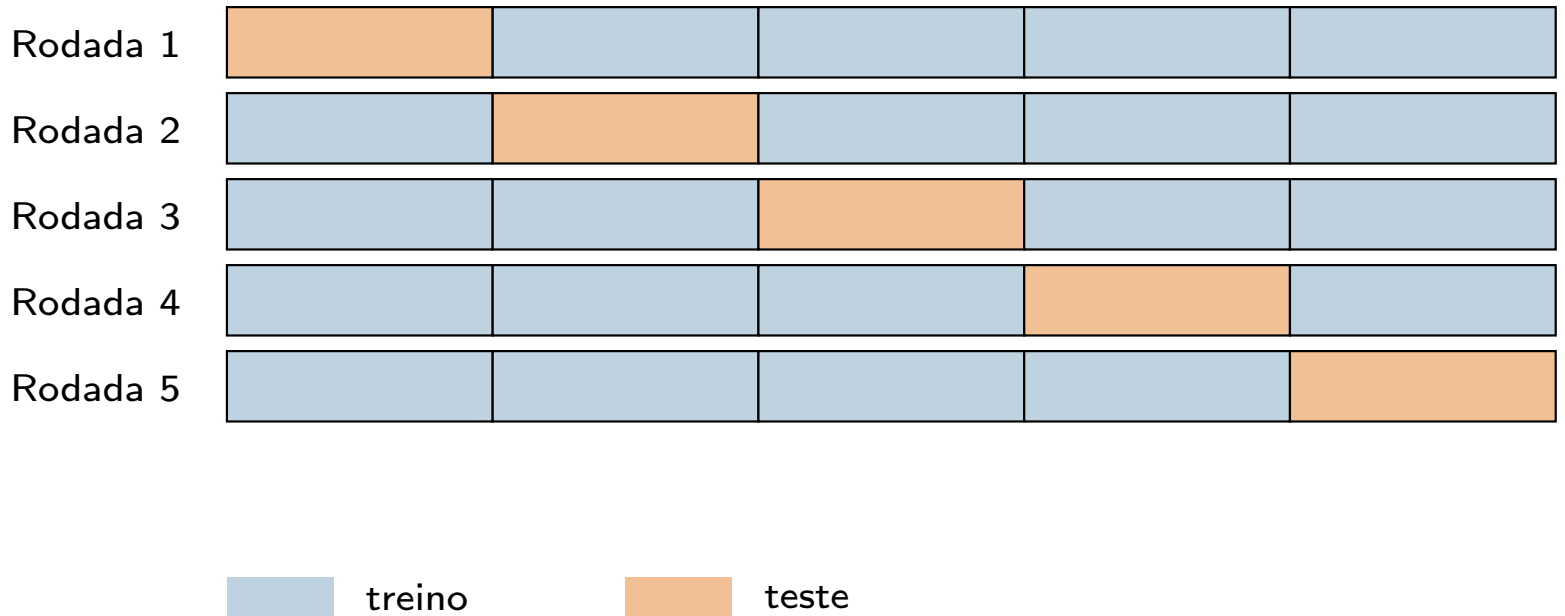
Seleção de modelos

- **Seleção**: escolher a família de hipóteses (árvores, redes, regressão).
- **Otimização**: achar a melhor hipótese dentro da família escolhida.
- O desafio é equilibrar underfitting e overfitting.

	Parâmetros	**Hiperparâmetros**
Quem define	o algoritmo, ao treinar	a pessoa, antes de treinar
Exemplos	pesos, coeficientes	k do k-NN, profundidade, λ



Cross-validation com k partições



- Cada partição serve uma vez como teste.
- O resultado é a média das k notas, com seu desvio padrão.

Cross-validation: um exemplo numérico

Cinco rodadas, acurácias de teste: 0,84, 0,88, 0,80, 0,86, 0,82.

$$\bar{a} = 0{,}84, \qquad s = \sqrt{\frac{0 + 0{,}0016 + 0{,}0016 + 0{,}0004 + 0{,}0004}{4}} \approx 0{,}032.$$

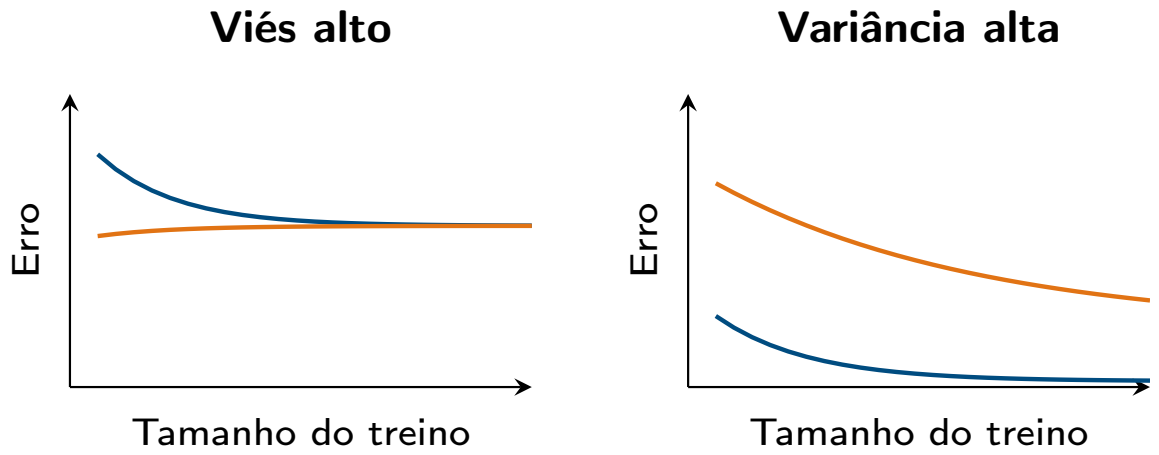
Relatamos $0{,}84 \pm 0{,}03$. A cross-validation reduz a variância da estimativa de desempenho, porque não depende de uma única divisão.

Para refletir

Dados de séries temporais podem ser embaralhados antes da divisão? Por quê?



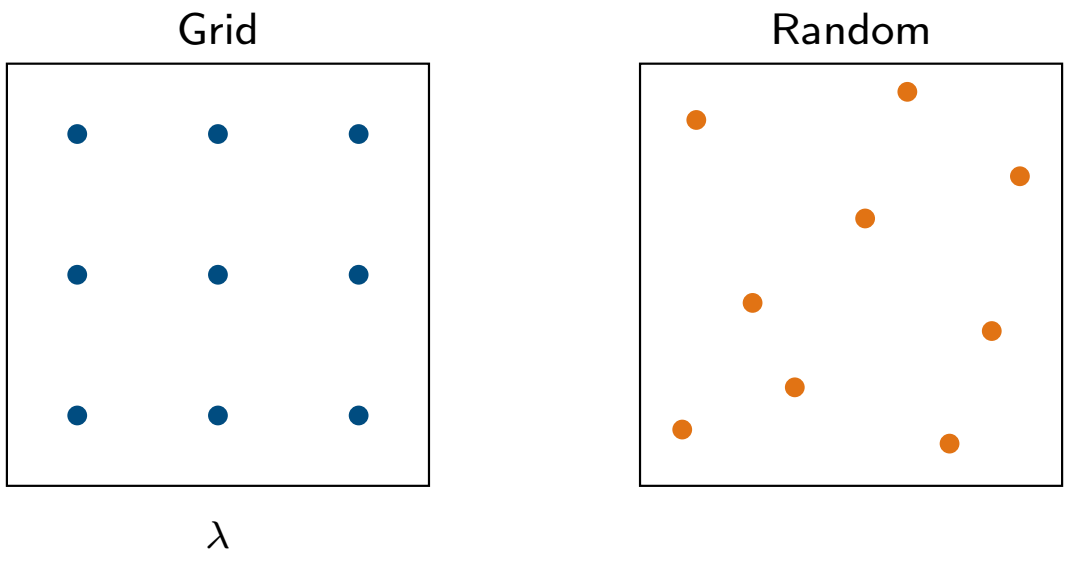
Curvas de aprendizado



azul: erro de treino. laranja: erro de teste (curvas ilustrativas).

No viés alto, mais dados não ajudam. Na variância alta, mais dados ajudam.

Busca de hiperparâmetros



Com a mesma quantidade de testes, a random search explora mais valores distintos de cada hiperparâmetro. A otimização bayesiana usa os resultados anteriores para escolher o próximo teste.

Matriz de confusão

		Previsto: Positivo	Previsto: Negativo
Real	Positivo	Verdadeiro Positivo (VP)	Falso Negativo (FN)
Real	Negativo	Falso Positivo (FP)	Verdadeiro Negativo (VN)

A diagonal mostra os acertos. Fora dela estão os dois tipos de erro.



VP, FN, FP, VN e suas equações

- **VP (verdadeiro positivo)**: positivo previsto e real positivo.
- **FN (falso negativo)**: negativo previsto, mas real positivo.
- **FP (falso positivo)**: positivo previsto, mas real negativo.
- **VN (verdadeiro negativo)**: negativo previsto e real negativo.

$$\text{Acurácia} = \frac{VP + VN}{VP + FN + FP + VN}$$

$$\text{Precisão} = \frac{VP}{VP + FP}$$

$$\text{Recall} = \frac{VP}{VP + FN}$$

$$F_1 = \frac{2 \cdot \text{Precisão} \cdot \text{Recall}}{\text{Precisão} + \text{Recall}}$$



Exemplo: filtro de spam

	Previsto spam	**Previsto não spam**
Real spam	50 (VP)	10 (FN)
Real não spam	5 (FP)	100 (VN)

Métrica	**Pergunta que responde**	**Valor**
Acurácia	quanto acertamos no total?	$\frac{150}{165} \approx 90{,}9\%$
Precisão	dos que previmos spam, quantos eram?	$\frac{50}{55} \approx 90{,}9\%$
Recall	dos spams reais, quantos achamos?	$\frac{50}{60} \approx 83{,}3\%$
F1	equilíbrio entre precisão e *recall*	$\frac{2 \cdot 50}{2 \cdot 50 + 5 + 10} \approx 0{,}87$



O paradoxo da acurácia

Em 1000 pacientes, apenas 10 têm a doença. Um modelo que responde sempre "saudável" obtém:

$$\text{acurácia} = \frac{990}{1000} = 99\%, \qquad \textit{recall} = \frac{0}{10} = 0\%.$$

Para refletir

Esse modelo é útil? Qual métrica revela o problema?

Com classes desbalanceadas, use *recall*, precisão, F1 e a matriz de confusão.



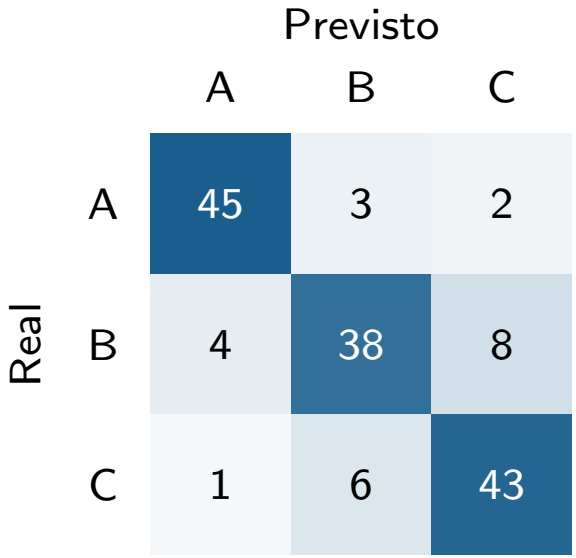
Qual erro custa mais?

Cenário	**Erro mais grave**	**Priorizar**
Triagem de câncer	falso negativo (doença não detectada)	*recall*
Filtro de spam	falso positivo (e-mail importante perdido)	precisão
Detecção de fraude	depende do custo da fraude e da revisão	ambos, via F1 ou custo

O limiar de decisão controla essa troca. Reduzir o limiar aumenta o *recall* e diminui a precisão.



Classificação multiclasse



	Prec.	*Recall*	F1
A	0,90	0,90	0,90
B	0,81	0,76	0,78
C	0,81	0,86	0,84

Acurácia: $126/150 = 84\%$. Média macro do F1: 0,84.

Cada linha soma os exemplos reais da classe. A classe B é a mais confundida.

Exercício

Um detector de fraude produziu $VP = 30$, $FN = 20$, $FP = 10$ e $VN = 940$.
Calcule acurácia, precisão, *recall* e F1.

Resposta

Acurácia $= 970/1000 = 97\%$. Precisão $= 30/40 = 0{,}75$. *Recall* $= 30/50 = 0{,}60$. F1 $= 60/90 \approx 0{,}67$.

A acurácia alta esconde que 40% das fraudes passam despercebidas.



Exercício

Um detector de fraude produziu $VP = 30$, $FN = 20$, $FP = 10$ e $VN = 940$.
Calcule acurácia, precisão, *recall* e F1.

Resposta

Acurácia $= 970/1000 = 97\%$. Precisão $= 30/40 = 0{,}75$. *Recall* $= 30/50 = 0{,}60$. F1 $= 60/90 \approx 0{,}67$.

A acurácia alta esconde que 40% das fraudes passam despercebidas.

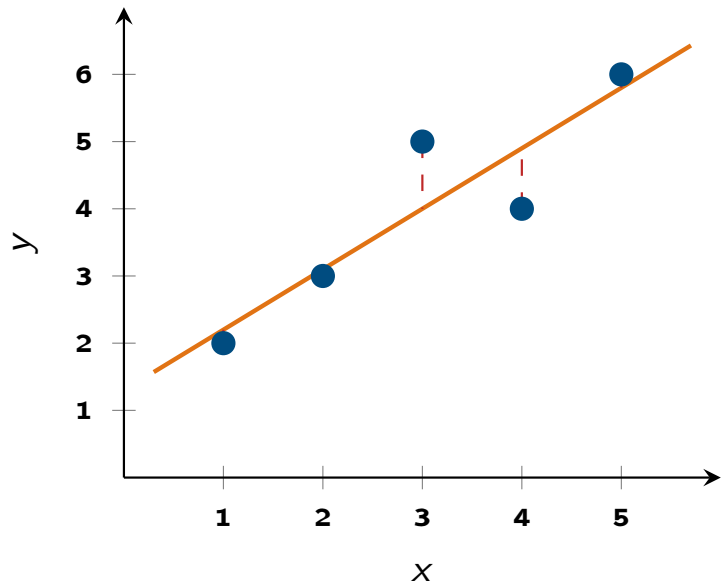


Regressão linear simples

$$y = \beta_0 + \beta_1 x + \varepsilon$$

- β_0: intercepto.
- β_1: variação esperada em y para cada unidade de x.
- ε: erro aleatório.

Os coeficientes minimizam a soma dos quadrados dos resíduos (mínimos quadrados).



Métricas de regressão

Métrica	Fórmula	No exemplo
MSE	$\frac{1}{n}\sum(y_i - \hat{y}_i)^2$	$1{,}90/5 = 0{,}38$
RMSE	$\sqrt{\text{MSE}}$	0,62, na unidade de y
MAE	$\frac{1}{n}\sum\lvert y_i - \hat{y}_i\rvert$	$2{,}4/5 = 0{,}48$
R^2	$1 - \frac{\sum(y_i-\hat{y}_i)^2}{\sum(y_i-\bar{y})^2}$	$1 - \frac{1{,}9}{10} = 0{,}81$

- O MSE pune erros grandes mais do que o MAE.
- R^2 pode ser **negativo** em dados de teste, quando o modelo é pior que a média.
- R^2 ajustado penaliza atributos que não ajudam.



Regressão múltipla

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p + \varepsilon \quad \Longleftrightarrow \quad \mathrm{y} = \mathrm{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}.$$

Com $\mathrm{X} \in \mathbb{R}^{n \times (p+1)}$ (primeira coluna de uns), a solução de mínimos quadrados é

$$\hat{\boldsymbol{\beta}} = (\mathrm{X}^\top \mathrm{X})^{-1} \mathrm{X}^\top \mathrm{y}.$$

Cada β_j mede o efeito de x_j **mantendo os demais fixos**. Exemplo: o preço de um imóvel cresce β_1 por metro quadrado, com o número de quartos constante.

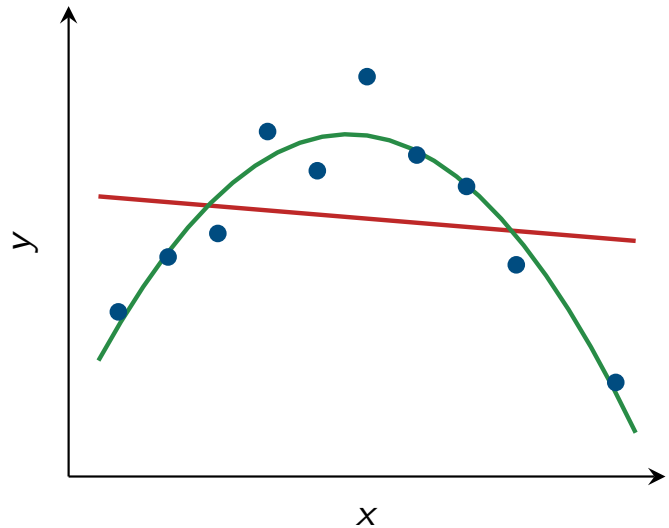


Regressão polinomial

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \cdots + \beta_d x^d$$

O modelo é **linear nos coeficientes**, mesmo com curva em x. Por isso os mesmos mínimos quadrados se aplicam.

Na figura de underfitting e overfitting, a reta tem SSE $= 11{,}9$ e a parábola $1{,}3$.



Regularização

Ideia: somar à perda uma **penalidade** sobre o tamanho dos coeficientes. Coeficientes grandes costumam causar overfitting.

Ridge (L2)

$\|y - X\beta\|^2 + \lambda \sum_j \beta_j^2$

- Penaliza o **quadrado** dos coeficientes.
- **Impacto:** encolhe todos, sem zerá-los.
- **Útil quando:** atributos são correlacionados.

Lasso (L1)

$\|y - X\beta\|^2 + \lambda \sum_j |\beta_j|$

- Penaliza o **valor absoluto** dos coeficientes.
- **Impacto:** zera coeficientes pouco úteis.
- **Útil quando:** há muitos atributos e queremos selecionar.

- λ controla a força: $\lambda = 0$ não penaliza; λ grande leva a underfitting.
- Padronize os atributos e escolha λ por cross-validation.

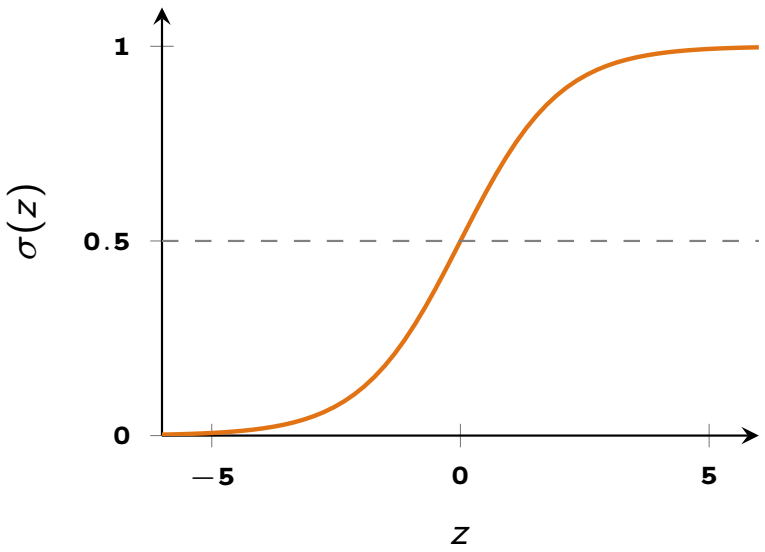
Regressão logística

Apesar do nome, é um **classificador**:

$$P(y = 1 \mid \mathrm{x}) = \sigma(z), \quad z = \mathrm{w}^\top \mathrm{x} + b.$$

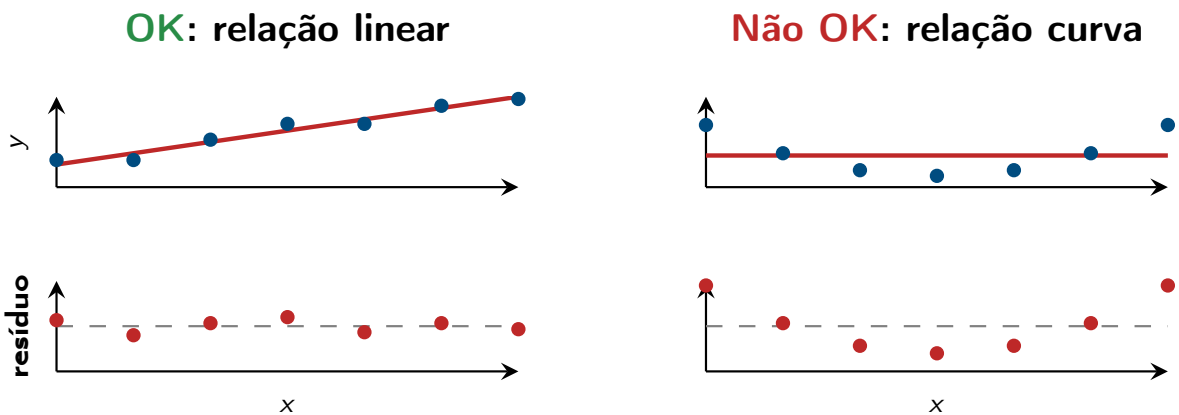
$$\sigma(z) = \frac{1}{1 + e^{-z}}.$$

Prevemos a classe 1 quando $P \geq 0{,}5$, isto é, quando $\mathrm{w}^\top \mathrm{x} + b \geq 0$. A perda é a entropia cruzada.



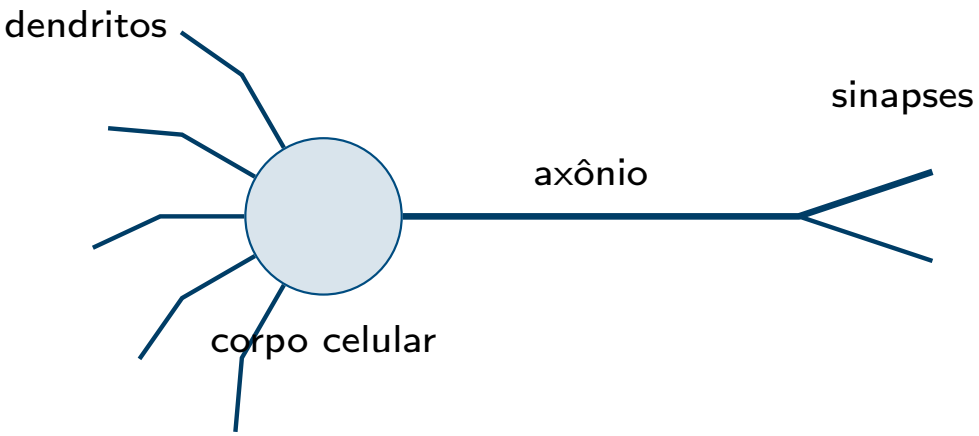
Suposições da regressão linear

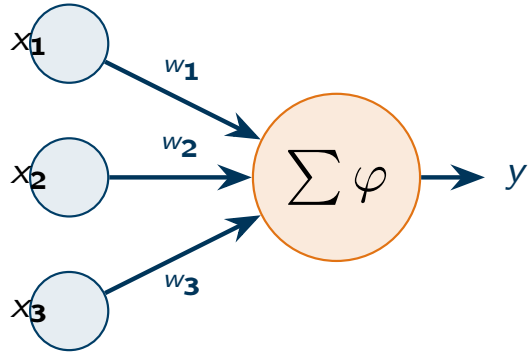
Suposição	Como verificar	Possível remédio
Linearidade (nos parâmetros)	resíduos contra valores previstos	transformar variáveis ou incluir termos polinomiais



Esquerda: os resíduos são aleatórios em torno de zero. Direita: os resíduos formam uma curva em U, indicando não linearidade.

Do neurônio biológico ao artificial





O neurônio artificial calcula $y = \varphi(\mathrm{w}^\top \mathrm{x} + b)$. A analogia biológica é inspiração e não um modelo fiel do cérebro.

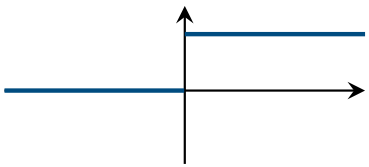
Neurônio biológico e artificial

	Biológico	**Artificial**
Entrada	sinais nas sinapses	vetor x
Força da conexão	eficácia sináptica	peso w_i
Disparo	potencial passa de um limiar	função de ativação φ
Escala	cerca de 10^{11} neurônios, até 10^4 conexões cada	de milhares a bilhões de parâmetros

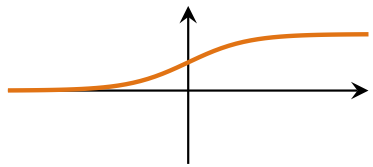


Funções de ativação

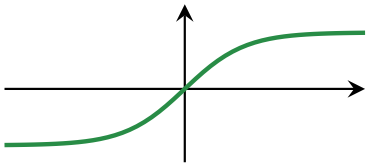
Degrau



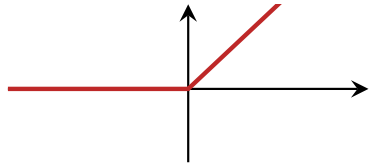
Sigmoide



Tanh



ReLU



Por que a não linearidade importa

Sem ativação não linear, camadas empilhadas colapsam em uma só:

$$W_2(W_1x + b_1) + b_2 = (W_2W_1)x + (W_2b_1 + b_2).$$

Função	**Uso típico**	**Observação**
Sigmoide	saída binária	satura e atenua gradientes
Tanh	camadas ocultas antigas	centrada em zero
ReLU	camadas ocultas modernas	simples e rápida
Softmax	saída multiclasse	produz probabilidades

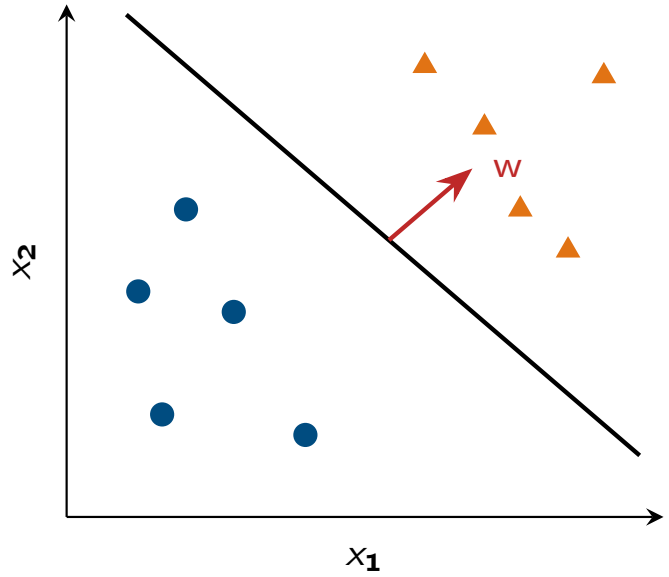


O Perceptron

Proposto por Rosenblatt (1958). Sobre o modelo de McCulloch e Pitts (1943), ele aprende os pesos:

$$\hat{y} = \begin{cases} 1, & \mathrm{w}^\top \mathrm{x} + b \geq 0 \\ 0, & \text{caso contrário.} \end{cases}$$

Geometricamente, a equação $\mathrm{w}^\top \mathrm{x} + b = 0$ é uma reta que separa as classes.



Porta AND com um neurônio

Escolhemos $w_1 = 1$, $w_2 = 1$ e $b = -1{,}5$. O neurônio calcula

$$u = 1 \cdot x_1 + 1 \cdot x_2 - 1{,}5, \qquad y = \begin{cases} 1 & u \geq 0 \\ 0 & u < 0 \end{cases}$$

x_1	x_2	$u = x_1 + x_2 - 1{,}5$	y
0	0	$0 + 0 - 1{,}5 = -1{,}5$	0
0	1	$0 + 1 - 1{,}5 = -0{,}5$	0
1	0	$1 + 0 - 1{,}5 = -0{,}5$	0
1	1	$1 + 1 - 1{,}5 = +0{,}5$	1

Só a entrada $(1, 1)$ soma o bastante para vencer o viés $b = -1{,}5$, então a saída é 1 apenas quando x_1 **e** x_2 são 1.



Regra de aprendizagem do Perceptron

O que cada símbolo significa

- x_1, x_2: entradas do exemplo; w_1, w_2: pesos (importância de cada entrada); b: viés.
- $u = w_1 x_1 + w_2 x_2 + b$: soma ponderada. A previsão é $\hat{y} = 1$ se $u \geq 0$ e $\hat{y} = 0$ caso contrário.
- y: resposta correta (alvo); $e = y - \hat{y}$: **erro**, que vale 0, $+1$ ou -1.
- η: taxa de aprendizado, o tamanho do passo (aqui, $\eta = 1$).

Atualização, após cada exemplo:

$$w_i \leftarrow w_i + \eta\, e\, x_i, \qquad b \leftarrow b + \eta\, e.$$



Por que a regra funciona

- $e = 0$ (acertou): w e b não mudam.
- $e = +1$ (previu 0, mas era 1): u estava baixo demais. Somamos ηx_i aos pesos e η ao viés, e u **aumenta**.
- $e = -1$ (previu 1, mas era 0): u estava alto demais. Subtraímos, e u **diminui**.
- Se $x_i = 0$, o peso w_i não muda, pois aquela entrada não contribuiu para o erro.
- O viés b se comporta como um peso de uma entrada que vale sempre 1.
- Se os dados são linearmente separáveis, o Perceptron converge em um número finito de passos.



Exemplo resolvido: aprendendo AND (passo a passo)

Dados: alvo $y = 1$ só para $(1, 1)$. **Início:** $w_1 = w_2 = 0$, $b = 0$, $\eta = 1$.

Para cada linha: (1) calcule $u = w_1 x_1 + w_2 x_2 + b$ com os pesos atuais; (2) $\hat{y} = 1$ se $u \geq 0$, senão 0; (3) $e = y - \hat{y}$; (4) se $e \neq 0$, atualize $w_1 \leftarrow w_1 + e\, x_1$, $w_2 \leftarrow w_2 + e\, x_2$, $b \leftarrow b + e$.

As colunas w_1, w_2, b mostram os valores **depois** da linha. Uma **época** é uma passada pelos 4 exemplos.

Exemplo da 1ª linha: $u = 0 \cdot 0 + 0 \cdot 0 + 0 = 0 \geq 0 \Rightarrow \hat{y} = 1$, mas $y = 0$. Logo $e = -1$ e $b \leftarrow 0 + (-1) = -1$. Os pesos w_1, w_2 não mudam, porque $x_1 = x_2 = 0$.



Aprendendo AND: época 1

x_1	x_2	y	$u = w_1x_1 + w_2x_2 + b$	$\hat{y}$	$e = y - \hat{y}$	w_1	w_2	b
0	0	0	$(0)(0) + (0)(0) + (0) = 0$	1	$0 - 1 = -1$	0	0	-1
$\Rightarrow$ erro: $w_1 = 0 + (-1)(0) = 0$, $w_2 = 0 + (-1)(0) = 0$, $b = 0 + (-1) = -1$								
0	1	0	$(0)(0) + (0)(1) + (-1) = -1$	0	$0 - 0 = 0$	0	0	-1
$\Rightarrow$ $e = 0$: nada muda								
1	0	0	$(0)(1) + (0)(0) + (-1) = -1$	0	$0 - 0 = 0$	0	0	-1
$\Rightarrow$ $e = 0$: nada muda								
1	1	1	$(0)(1) + (0)(1) + (-1) = -1$	0	$1 - 0 = 1$	1	1	0
$\Rightarrow$ erro: $w_1 = 0 + (1)(1) = 1$, $w_2 = 0 + (1)(1) = 1$, $b = -1 + (1) = 0$								

Cores: w_1, w_2, b e erro e.

Seguimos para a próxima época com $w_1 = 1$, $w_2 = 1$, $b = 0$.



Aprendendo AND: época 2

x_1	x_2	y	$u = w_1 x_1 + w_2 x_2 + b$	$\hat{y}$	$e = y - \hat{y}$	w_1	w_2	b
0	0	0	$(1)(0) + (1)(0) + (0) = 0$	1	$0 - 1 = -1$	1	1	-1
$\Rightarrow$ erro:	$w_1 = 1 + (-1)(0) = 1$,	$w_2 = 1 + (-1)(0) = 1$,	$b = 0 + (-1) = -1$					
0	1	0	$(1)(0) + (1)(1) + (-1) = 0$	1	$0 - 1 = -1$	1	0	-2
$\Rightarrow$ erro:	$w_1 = 1 + (-1)(0) = 1$,	$w_2 = 1 + (-1)(1) = 0$,	$b = -1 + (-1) = -2$					
1	0	0	$(1)(1) + (0)(0) + (-2) = -1$	0	$0 - 0 = 0$	1	0	-2
$\Rightarrow$ $e = 0$: nada muda								
1	1	1	$(1)(1) + (0)(1) + (-2) = -1$	0	$1 - 0 = 1$	2	1	-1
$\Rightarrow$ erro:	$w_1 = 1 + (1)(1) = 2$,	$w_2 = 0 + (1)(1) = 1$,	$b = -2 + (1) = -1$					

Cores: w_1, w_2, b e erro e.

Seguimos para a próxima época com $w_1 = 2$, $w_2 = 1$, $b = -1$.



Aprendendo AND: época 3

x_1	x_2	y	$u = w_1 x_1 + w_2 x_2 + b$	$\hat{y}$	$e = y - \hat{y}$	w_1	w_2	b
0	0	0	$(2)(0) + (1)(0) + (-1) = -1$	0	$0 - 0 = 0$	2	1	-1
$\Rightarrow$ $e = 0$: nada muda								
0	1	0	$(2)(0) + (1)(1) + (-1) = 0$	1	$0 - 1 = -1$	2	0	-2
$\Rightarrow$ erro: $w_1 = 2 + (-1)(0) = 2$, $w_2 = 1 + (-1)(1) = 0$, $b = -1 + (-1) = -2$								
1	0	0	$(2)(1) + (0)(0) + (-2) = 0$	1	$0 - 1 = -1$	1	0	-3
$\Rightarrow$ erro: $w_1 = 2 + (-1)(1) = 1$, $w_2 = 0 + (-1)(0) = 0$, $b = -2 + (-1) = -3$								
1	1	1	$(1)(1) + (0)(1) + (-3) = -2$	0	$1 - 0 = 1$	2	1	-2
$\Rightarrow$ erro: $w_1 = 1 + (1)(1) = 2$, $w_2 = 0 + (1)(1) = 1$, $b = -3 + (1) = -2$								

Cores: w_1, w_2, b e erro e.

Seguimos para a próxima época com $w_1 = 2$, $w_2 = 1$, $b = -2$.



Aprendendo AND: época 4

x_1	x_2	y	$u = w_1 x_1 + w_2 x_2 + b$	$\hat{y}$	$e = y - \hat{y}$	w_1	w_2	b
0	0	0	$(2)(0) + (1)(0) + (-2) = -2$	0	$0 - 0 = 0$	2	1	-2
$\Rightarrow$ $e = 0$: nada muda								
0	1	0	$(2)(0) + (1)(1) + (-2) = -1$	0	$0 - 0 = 0$	2	1	-2
$\Rightarrow$ $e = 0$: nada muda								
1	0	0	$(2)(1) + (1)(0) + (-2) = 0$	1	$0 - 1 = -1$	1	1	-3
$\Rightarrow$ erro: $w_1 = 2 + (-1)(1) = 1$, $w_2 = 1 + (-1)(0) = 1$, $b = -2 + (-1) = -3$								
1	1	1	$(1)(1) + (1)(1) + (-3) = -1$	0	$1 - 0 = 1$	2	2	-2
$\Rightarrow$ erro: $w_1 = 1 + (1)(1) = 2$, $w_2 = 1 + (1)(1) = 2$, $b = -3 + (1) = -2$								

Cores: w_1, w_2, b e erro e.

Seguimos para a próxima época com $w_1 = 2$, $w_2 = 2$, $b = -2$.



Aprendendo AND: época 5

x_1	x_2	y	$u = w_1x_1 + w_2x_2 + b$	$\hat{y}$	$e = y - \hat{y}$	w_1	w_2	b
0	0	0	$(2)(0) + (2)(0) + (-2) = -2$	0	$0 - 0 = 0$	2	2	-2
$\Rightarrow$ $e = 0$: nada muda								
0	1	0	$(2)(0) + (2)(1) + (-2) = 0$	1	$0 - 1 = -1$	2	1	-3
$\Rightarrow$ erro: $w_1 = 2 + (-1)(0) = 2$, $w_2 = 2 + (-1)(1) = 1$, $b = -2 + (-1) = -3$								
1	0	0	$(2)(1) + (1)(0) + (-3) = -1$	0	$0 - 0 = 0$	2	1	-3
$\Rightarrow$ $e = 0$: nada muda								
1	1	1	$(2)(1) + (1)(1) + (-3) = 0$	1	$1 - 1 = 0$	2	1	-3
$\Rightarrow$ $e = 0$: nada muda								

Cores: w_1, w_2, b e erro e.

Seguimos para a próxima época com $w_1 = 2$, $w_2 = 1$, $b = -3$.



Aprendendo AND: época 6

x_1	x_2	y	$u = w_1x_1 + w_2x_2 + b$	$\hat{y}$	$e = y - \hat{y}$	w_1	w_2	b
0	0	0	$(2)(0) + (1)(0) + (-3) = -3$	0	$0 - 0 = 0$	2	1	-3
$\Rightarrow e = 0$: nada muda								
0	1	0	$(2)(0) + (1)(1) + (-3) = -2$	0	$0 - 0 = 0$	2	1	-3
$\Rightarrow e = 0$: nada muda								
1	0	0	$(2)(1) + (1)(0) + (-3) = -1$	0	$0 - 0 = 0$	2	1	-3
$\Rightarrow e = 0$: nada muda								
1	1	1	$(2)(1) + (1)(1) + (-3) = 0$	1	$1 - 1 = 0$	2	1	-3
$\Rightarrow e = 0$: nada muda								

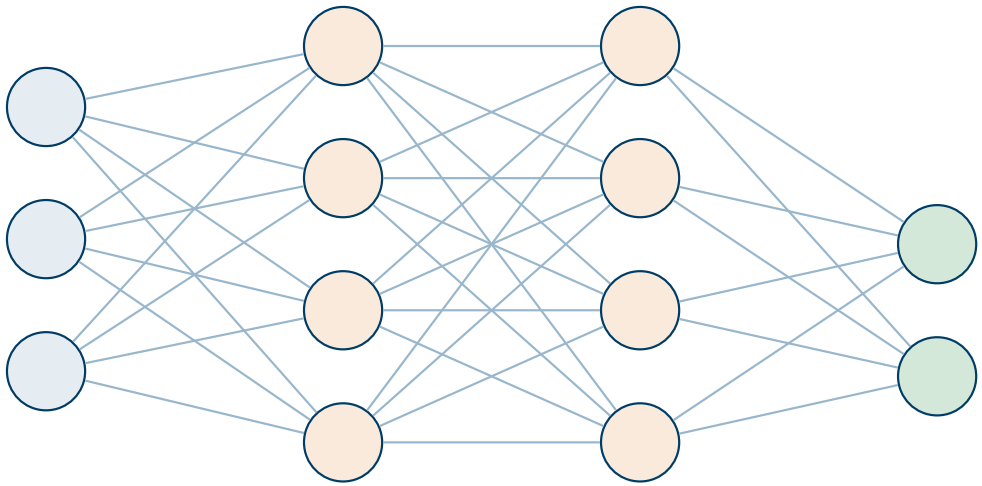
Cores: w_1, w_2, b e erro e.

Nenhum erro: o neurônio aprendeu AND com $w_1 = 2$, $w_2 = 1$, $b = -3$.

Conferência: $(1, 1) \Rightarrow u = 0 \geq 0$; as outras entradas dão $u < 0$.



Perceptron multicamadas (MLP)



entrada camadas ocultas saída

Cada camada densa calcula $L(\mathrm{x}) = \varphi(W\mathrm{x} + \mathrm{b})$, com $W \in \mathbb{R}^{m \times n}$ para n entradas e m neurônios.



Composição de camadas

$$f(\mathrm{x}) = \varphi_2\big(W_2\,\varphi_1(W_1\mathrm{x} + \mathrm{b}_1) + \mathrm{b}_2\big).$$

- As primeiras camadas extraem atributos simples (bordas, texturas).
- As camadas seguintes os combinam em conceitos (partes, objetos).
- Chamamos de **profunda** a rede com duas ou mais camadas ocultas.
- **Teorema da aproximação universal**: uma rede com uma camada oculta suficientemente larga aproxima qualquer função contínua em um conjunto compacto. O teorema garante a existência, mas não ensina a encontrar os pesos.



Função de perda: o que é

A **função de perda** $\mathcal{L}$ mede, com um único número, **o quanto a rede erra**. Treinar é ajustar w e b para minimizá-la.

- m: número de exemplos; i: índice do exemplo.
- y_i: valor correto (alvo); $\hat{y}_i$: previsão da rede.
- Perda pequena $\Rightarrow$ previsões próximas dos alvos; perda grande $\Rightarrow$ rede errando muito.
- O gradiente descendente usa a derivada de $\mathcal{L}$ para decidir como mudar os pesos.

A escolha depende da tarefa:

Tarefa	Perda
Prever um número (preço, temperatura)	MSE
Duas classes (fraude ou não)	Entropia cruzada binária
Várias classes (dígitos 0 a 9)	Entropia cruzada categórica



Regressão: erro quadrático médio (MSE)

$$\mathcal{L} = \frac{1}{m} \sum_{i=1}^{m} (y_i - \hat{y}_i)^2$$

- **O que faz:** calcula a média do quadrado da diferença entre o valor real e o previsto.
- **Por que o quadrado:** erros positivos e negativos não se cancelam, e erros grandes pesam muito mais. Errar 10 custa 100; errar 1 custa 1.
- **Cuidado:** é sensível a outliers, pois um valor extremo domina a média.
- **Onde é usada:** previsão de preços, demanda, temperatura e qualquer saída numérica contínua. Camada de saída linear.



Classificação binária: entropia cruzada binária

$$\mathcal{L} = -\frac{1}{m}\sum_{i=1}^{m}\left[y_i \log \hat{y}_i + (1-y_i)\log(1-\hat{y}_i)\right]$$

- **Entradas:** $y_i \in \{0,1\}$ e $\hat{y}_i \in (0,1)$ é a probabilidade da classe 1 (saída sigmoide).
- **O que faz:** se $y_i = 1$, sobra $-\log \hat{y}_i$; se $y_i = 0$, sobra $-\log(1-\hat{y}_i)$. Só conta a probabilidade dada à classe correta.
- **Efeito:** errar com confiança é punido muito. Se $y = 1$ e $\hat{y} = 0{,}01$, a perda é $-\log 0{,}01 \approx 4{,}6$; se $\hat{y} = 0{,}9$, é $\approx 0{,}1$.
- **Onde é usada:** detecção de fraude, spam, diagnóstico sim/não.



Multiclasse: entropia cruzada categórica

$$\mathcal{L} = -\frac{1}{m}\sum_{i=1}^{m}\sum_{k=1}^{K} y_{ik} \log \hat{y}_{ik}$$

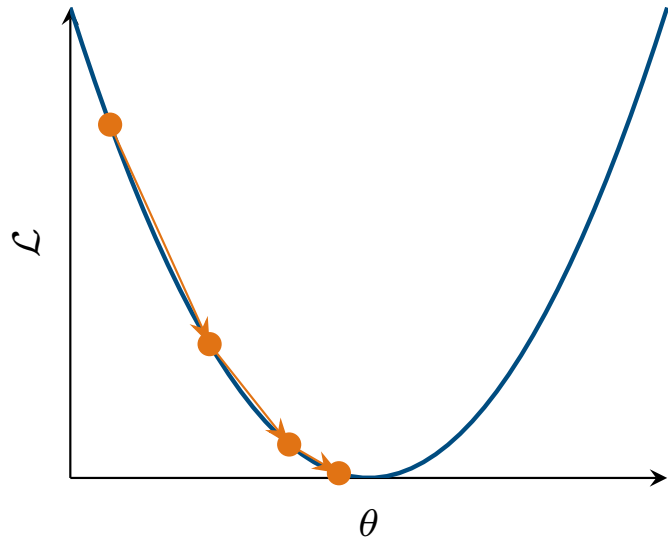
- **Entradas:** K classes; $y_{ik} = 1$ se o exemplo i pertence à classe k e 0 nas demais (one-hot); $\hat{y}_{ik}$ é a probabilidade prevista para a classe k (saída softmax).
- **O que faz:** como só um y_{ik} vale 1, a perda é $-\log$ da probabilidade dada à classe correta.
- **Relação:** com $K = 2$ ela se reduz à entropia cruzada binária.
- **Onde é usada:** reconhecimento de dígitos, classificação de imagens, de textos e de sentimentos.



Gradiente descendente

$$\theta \leftarrow \theta - \eta \nabla_\theta \mathcal{L}(\theta)$$

- η é a taxa de aprendizado.
- *Mini-batch*: o gradiente usa um subconjunto dos dados por passo.
- Uma *época* percorre todos os dados uma vez.
- Otimizadores como Adam adaptam o passo a cada parâmetro.



Retropropagação (backpropagation): o que é

Problema: uma rede tem milhares ou milhões de pesos. Como saber quanto cada um contribuiu para o erro e como corrigi-lo?

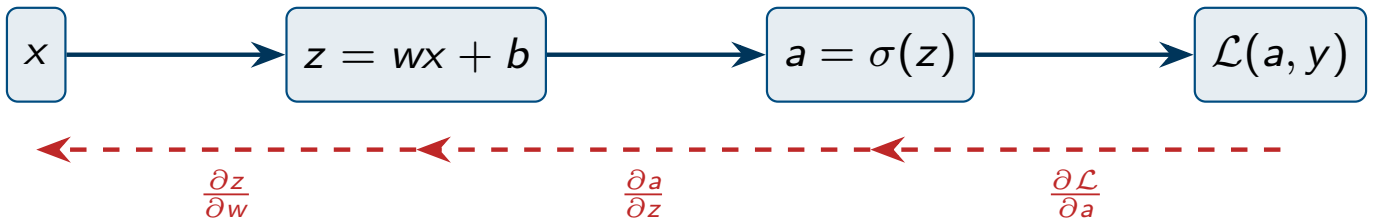
Solução: o algoritmo de retropropagação calcula $\frac{\partial \mathcal{L}}{\partial w}$ para **todos** os pesos de uma só vez.

1. **Forward:** passa a entrada pela rede e calcula a previsão $\hat{y}$.
2. **Perda:** compara $\hat{y}$ com y e calcula $\mathcal{L}$.
3. **Backward:** propaga o erro da saída até a entrada, calculando o gradiente de cada peso.
4. **Atualização:** $w \leftarrow w - \eta \frac{\partial \mathcal{L}}{\partial w}$ (gradiente descendente).

Importância: reaproveita cálculos de cada camada, então custa quase o mesmo que um forward. Sem ele, treinar redes profundas seria inviável.



Retropropagação: a matemática



$$\frac{\partial \mathcal{L}}{\partial w} = \frac{\partial \mathcal{L}}{\partial a} \cdot \frac{\partial a}{\partial z} \cdot \frac{\partial z}{\partial w} \qquad \text{(regra da cadeia)}$$

Cada fator é uma derivada local, fácil de calcular:

- $\partial z/\partial w = x$ (pois $z = wx + b$)
- $\partial a/\partial z = \sigma(z)(1 - \sigma(z)) = a(1 - a)$ (derivada da sigmoide)
- $\partial \mathcal{L}/\partial a$ depende da perda; com MSE, $\mathcal{L} = \frac{1}{2}(a - y)^2$ e vale $a - y$.

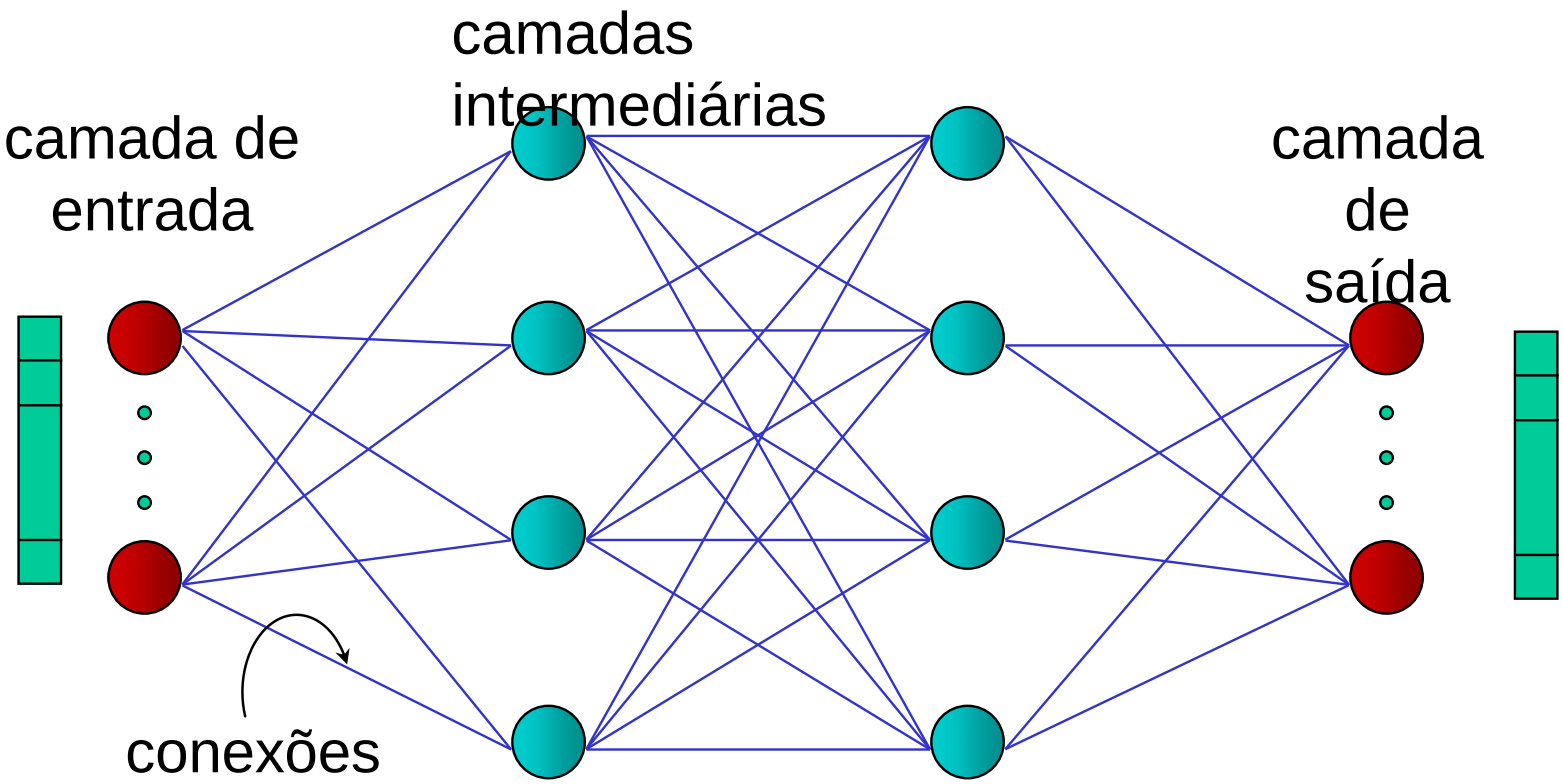
Logo $\partial \mathcal{L}/\partial w = (a - y)\, a(1 - a)\, x$. Com várias camadas, repete-se a regra da cadeia de trás para frente.

Animação do aprendizado

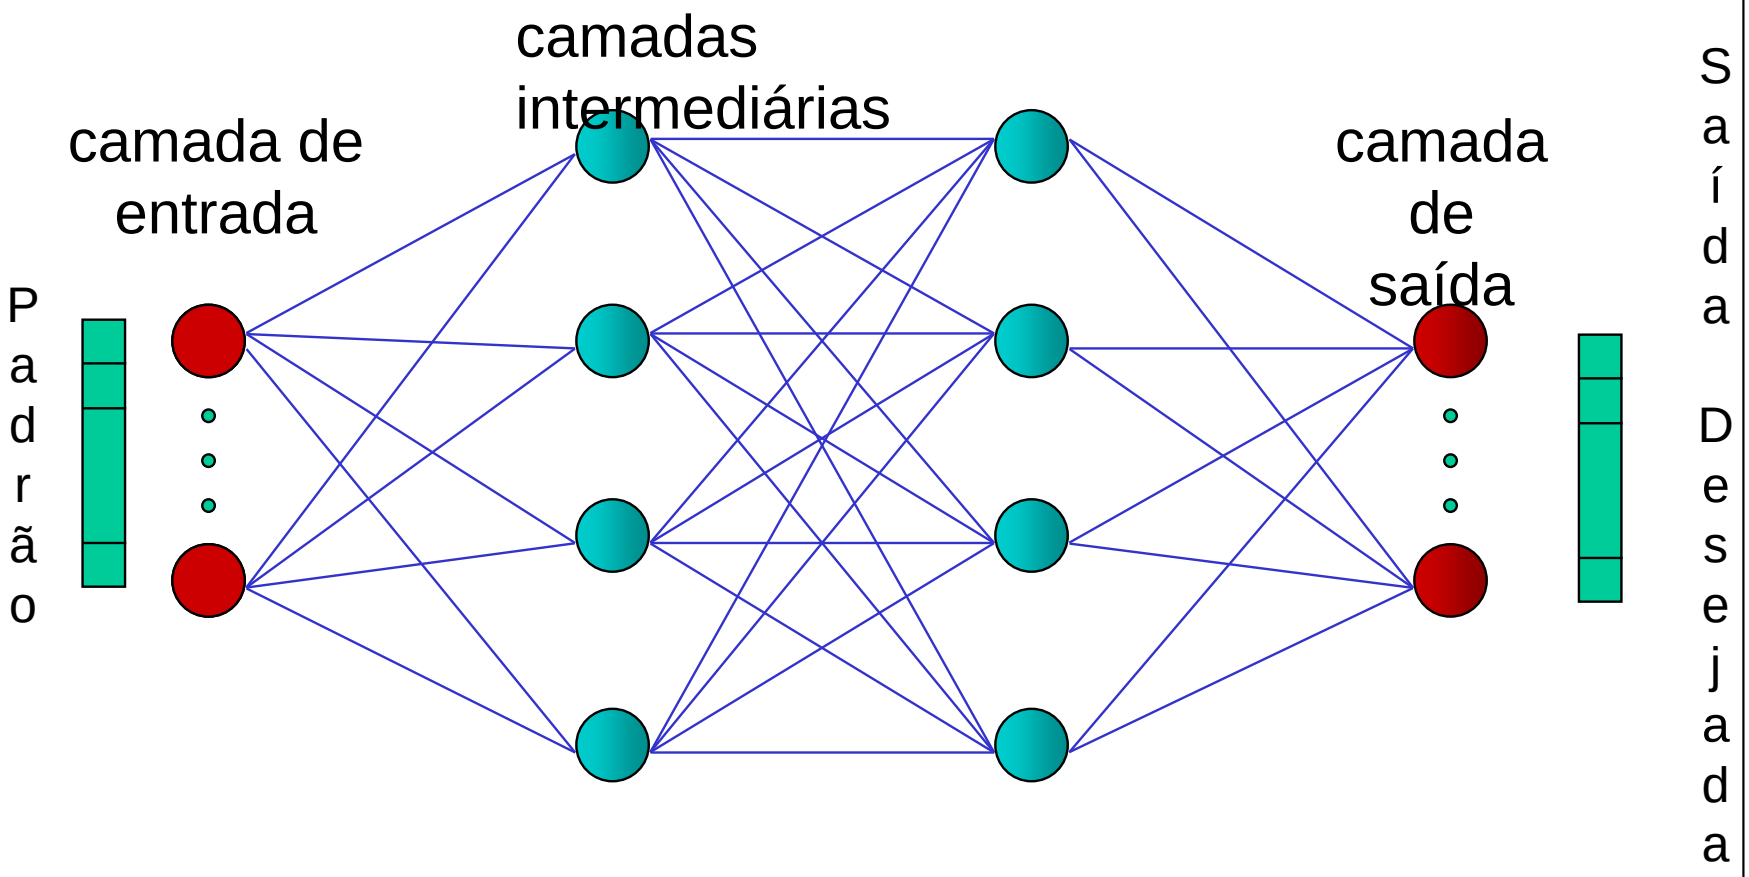
A seguir, uma sequência de quadros mostra a rede ajustando seus pesos.



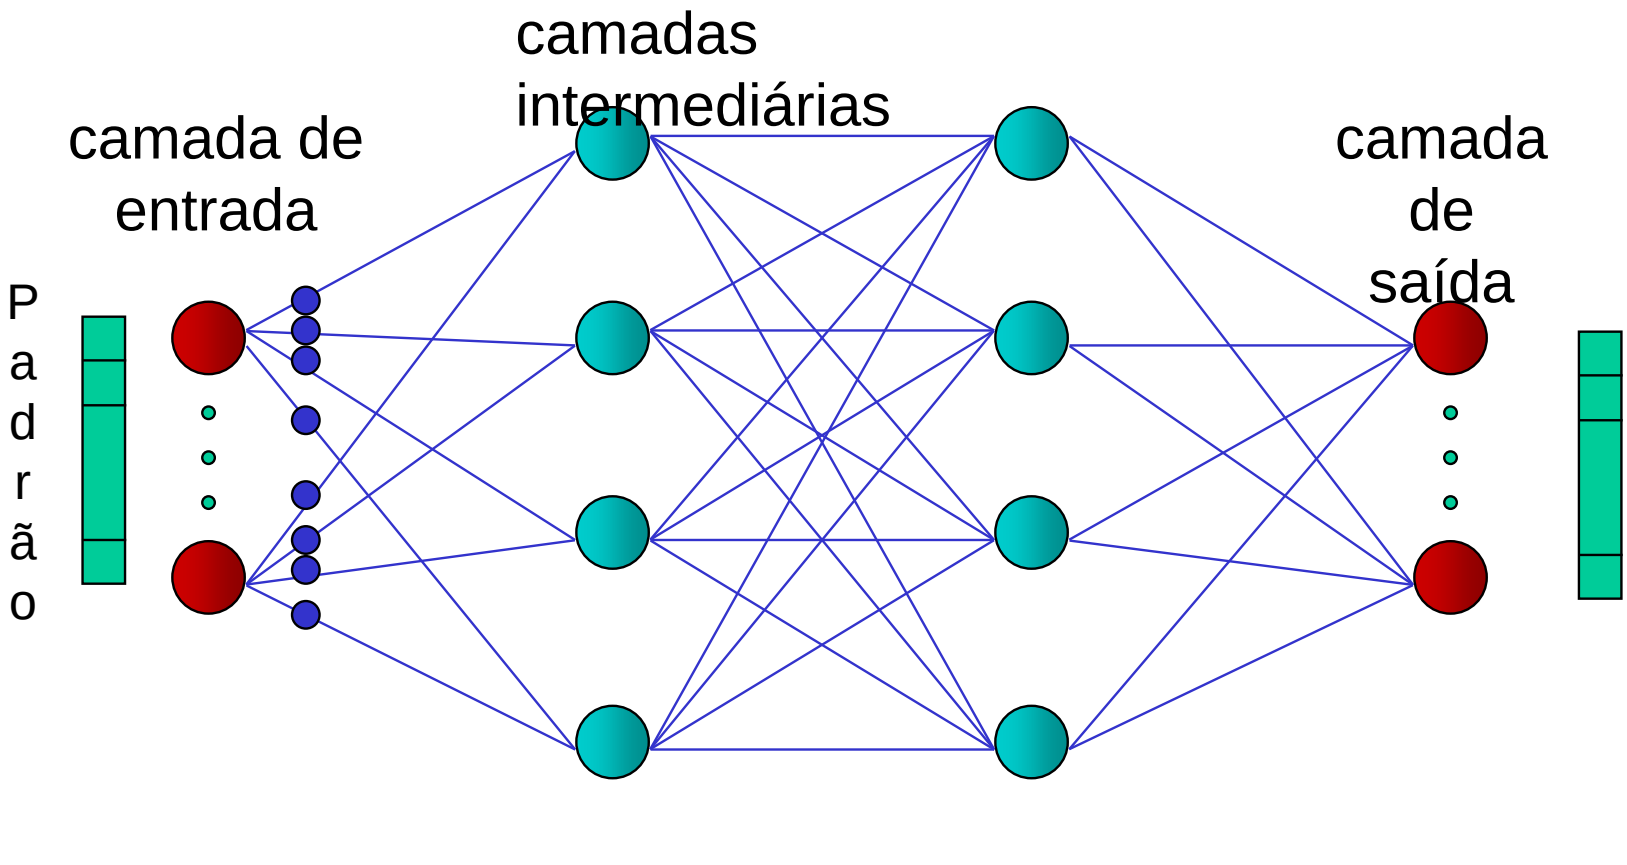
Rede MLP


camadas
intermediárias
camada de
entrada
camada
de
saída
conexões

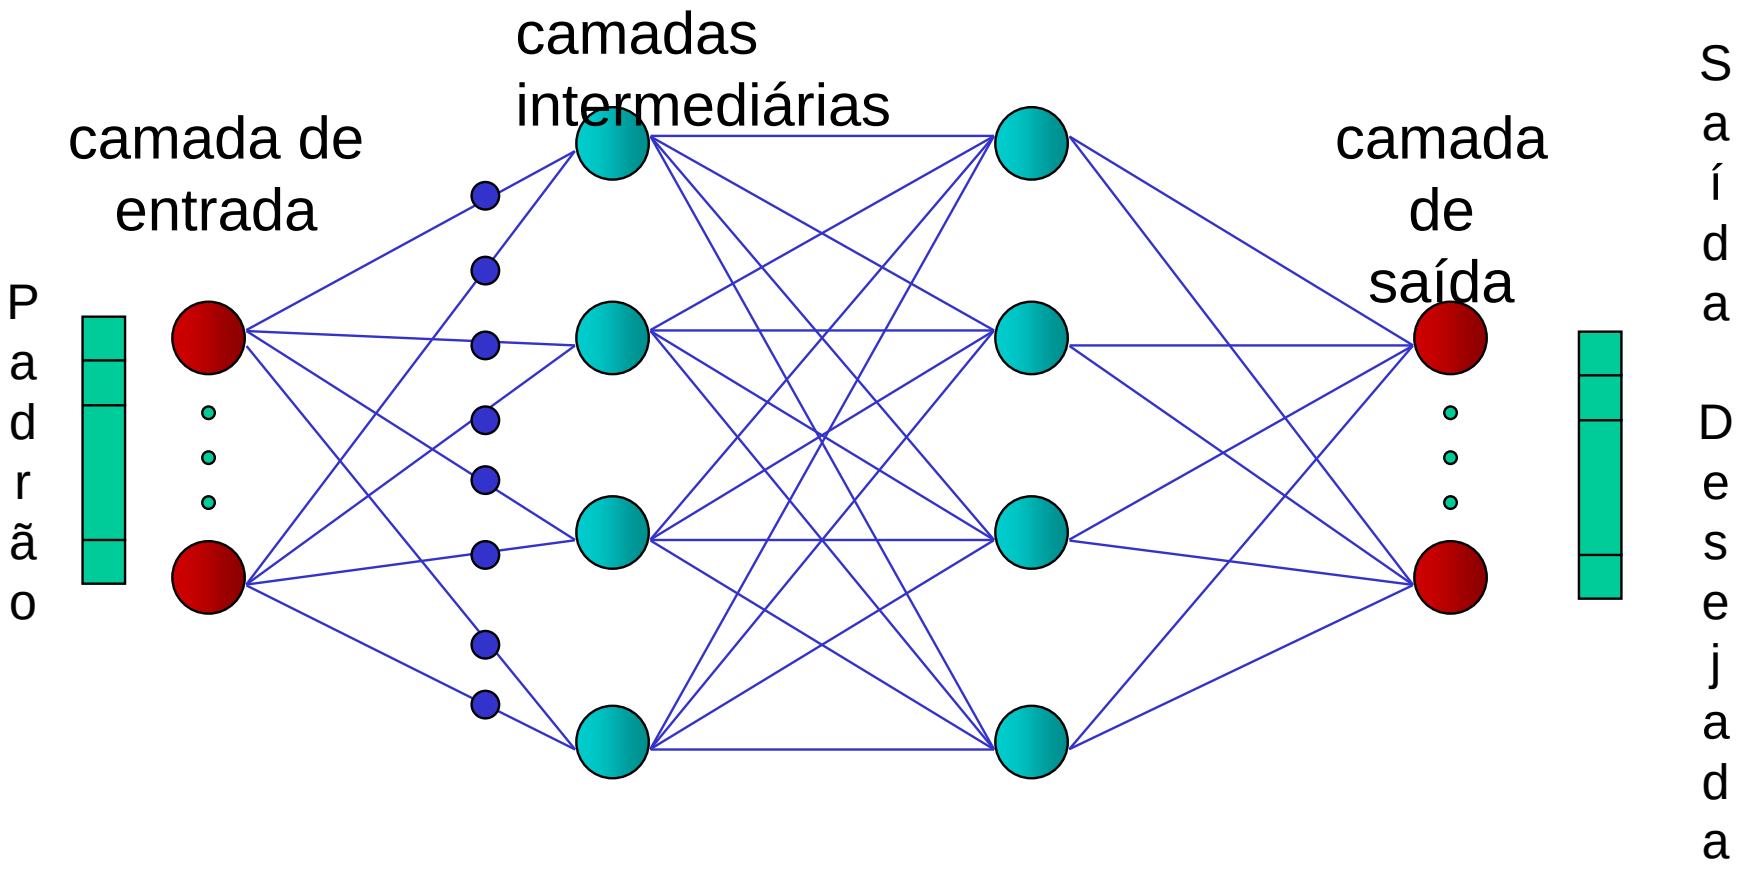
Aprendizado



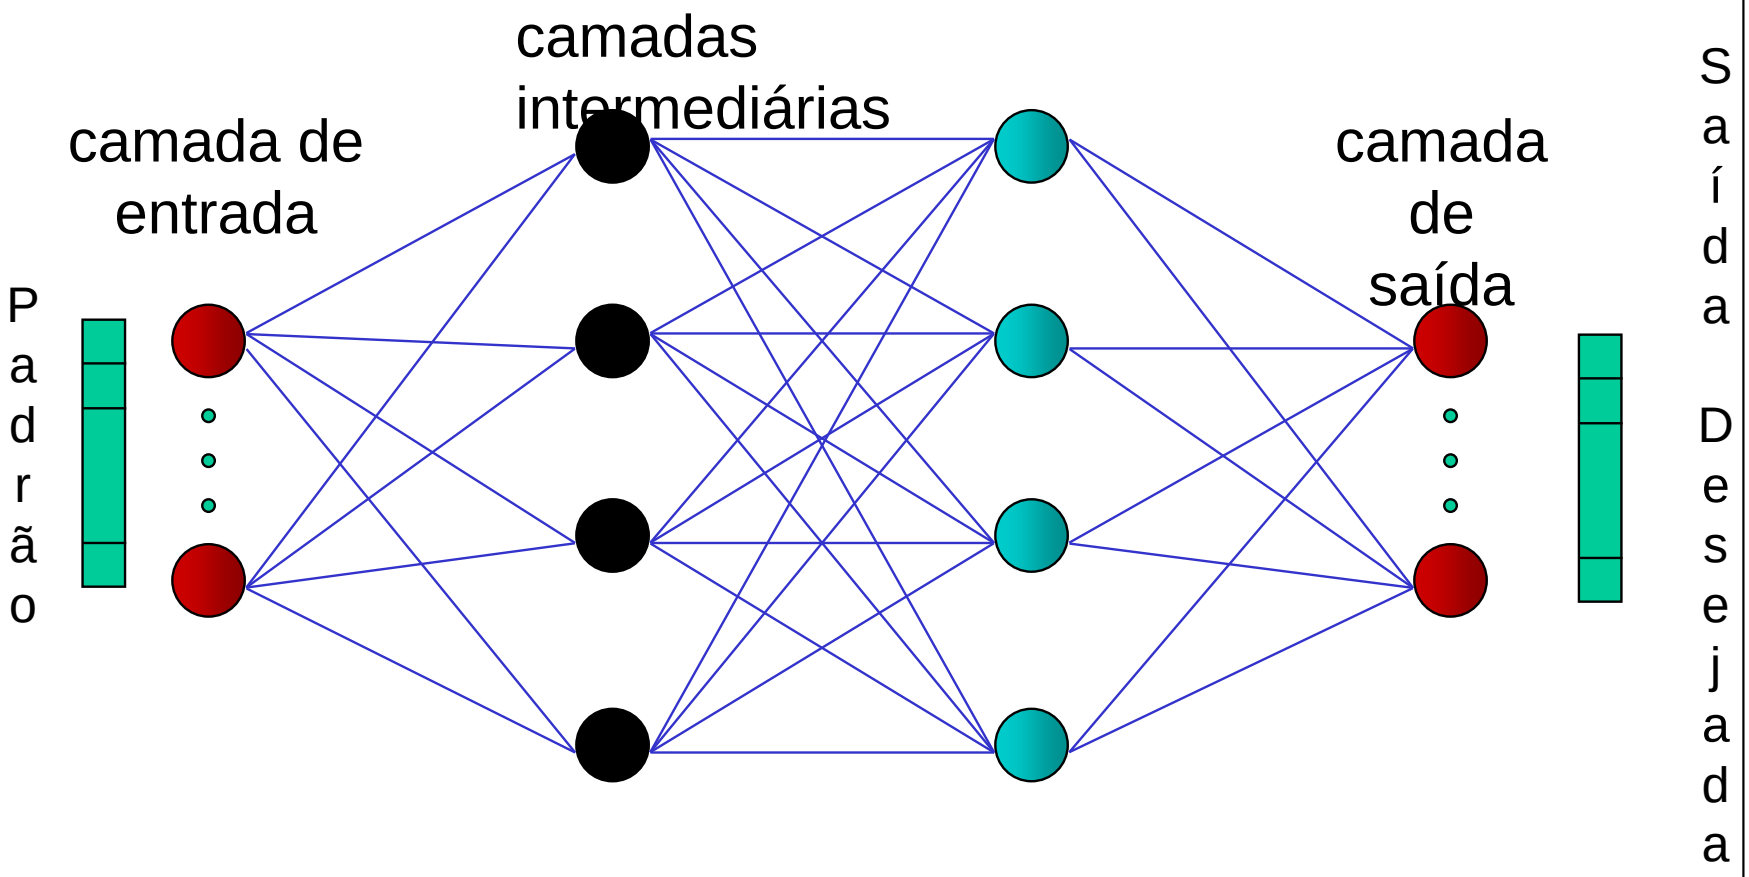
RNA - Aprendizado



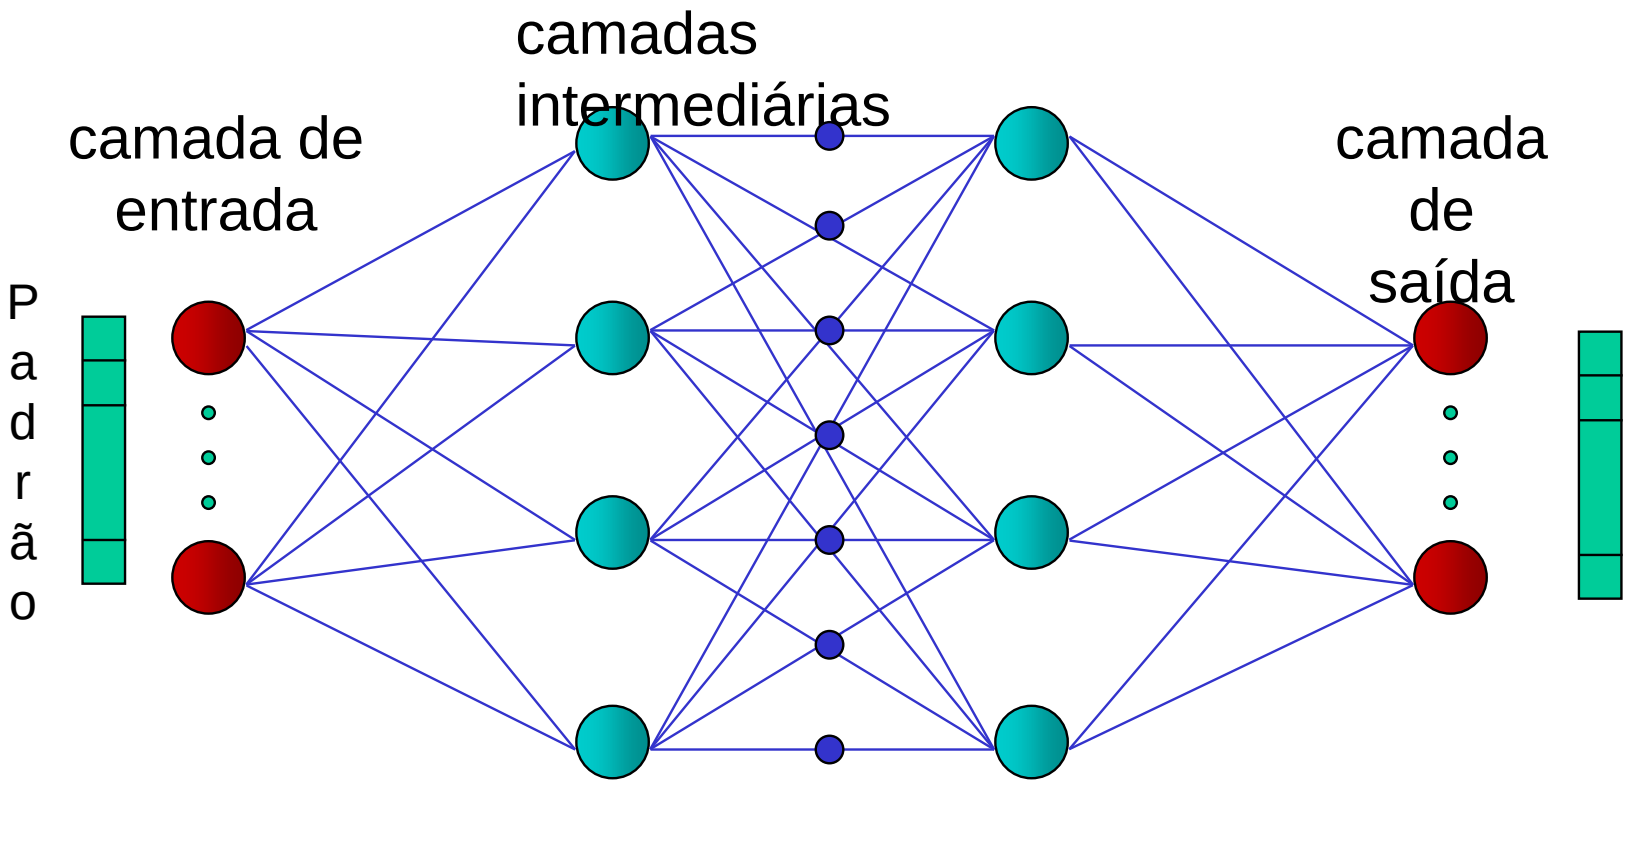
RNA - Aprendizado



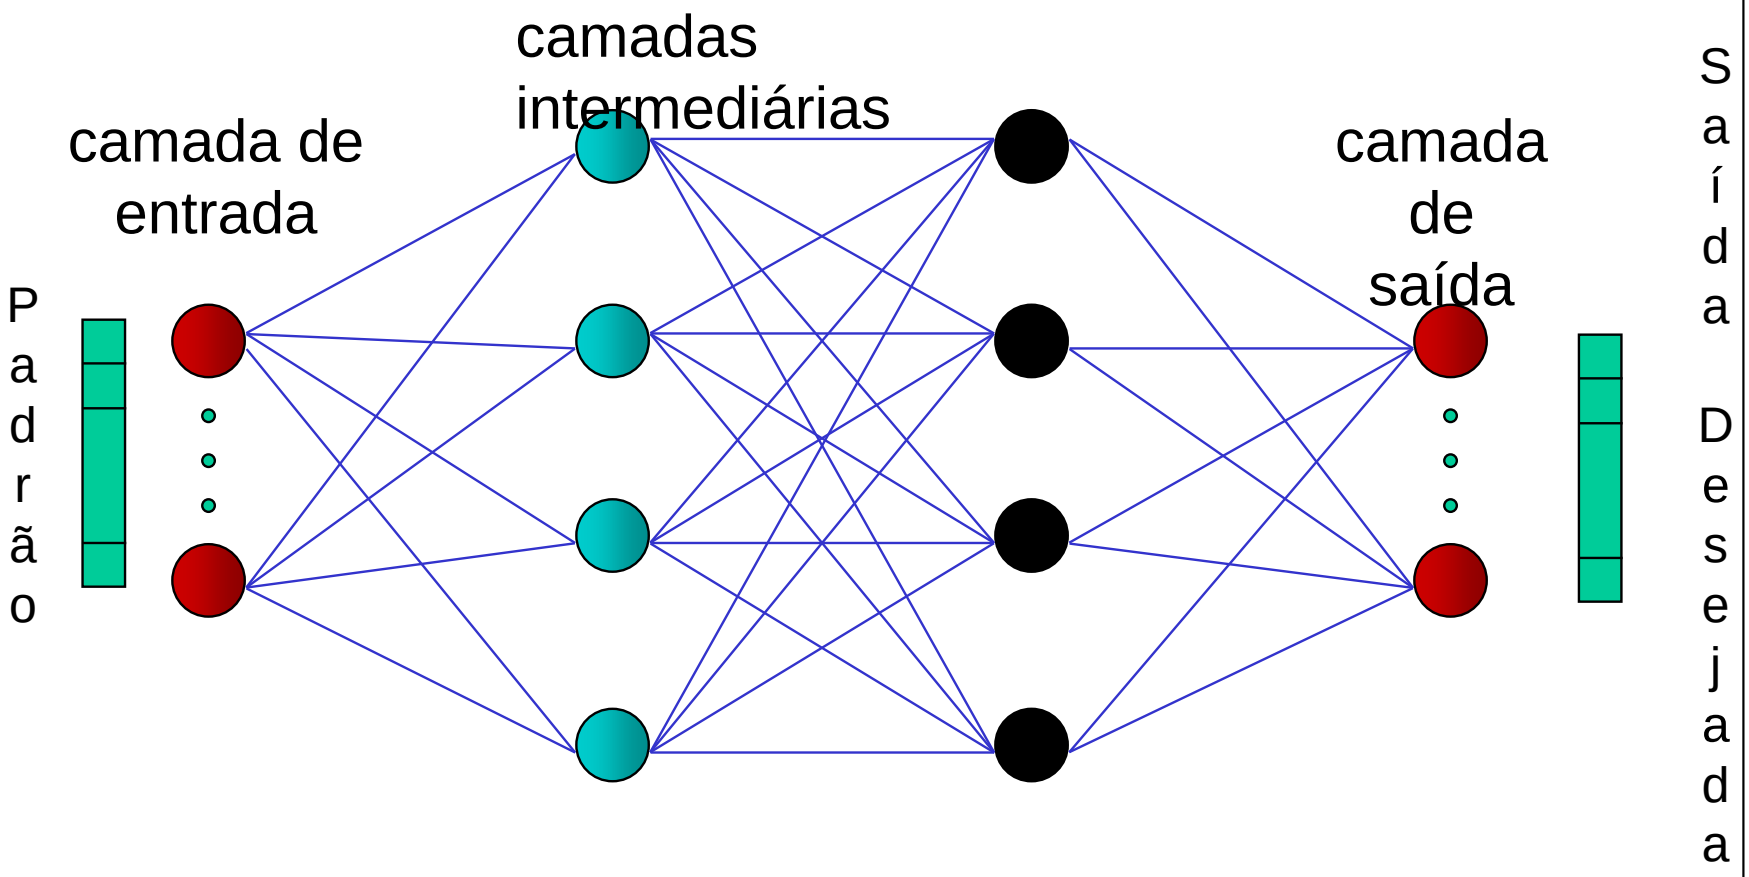
RNA - Aprendizado



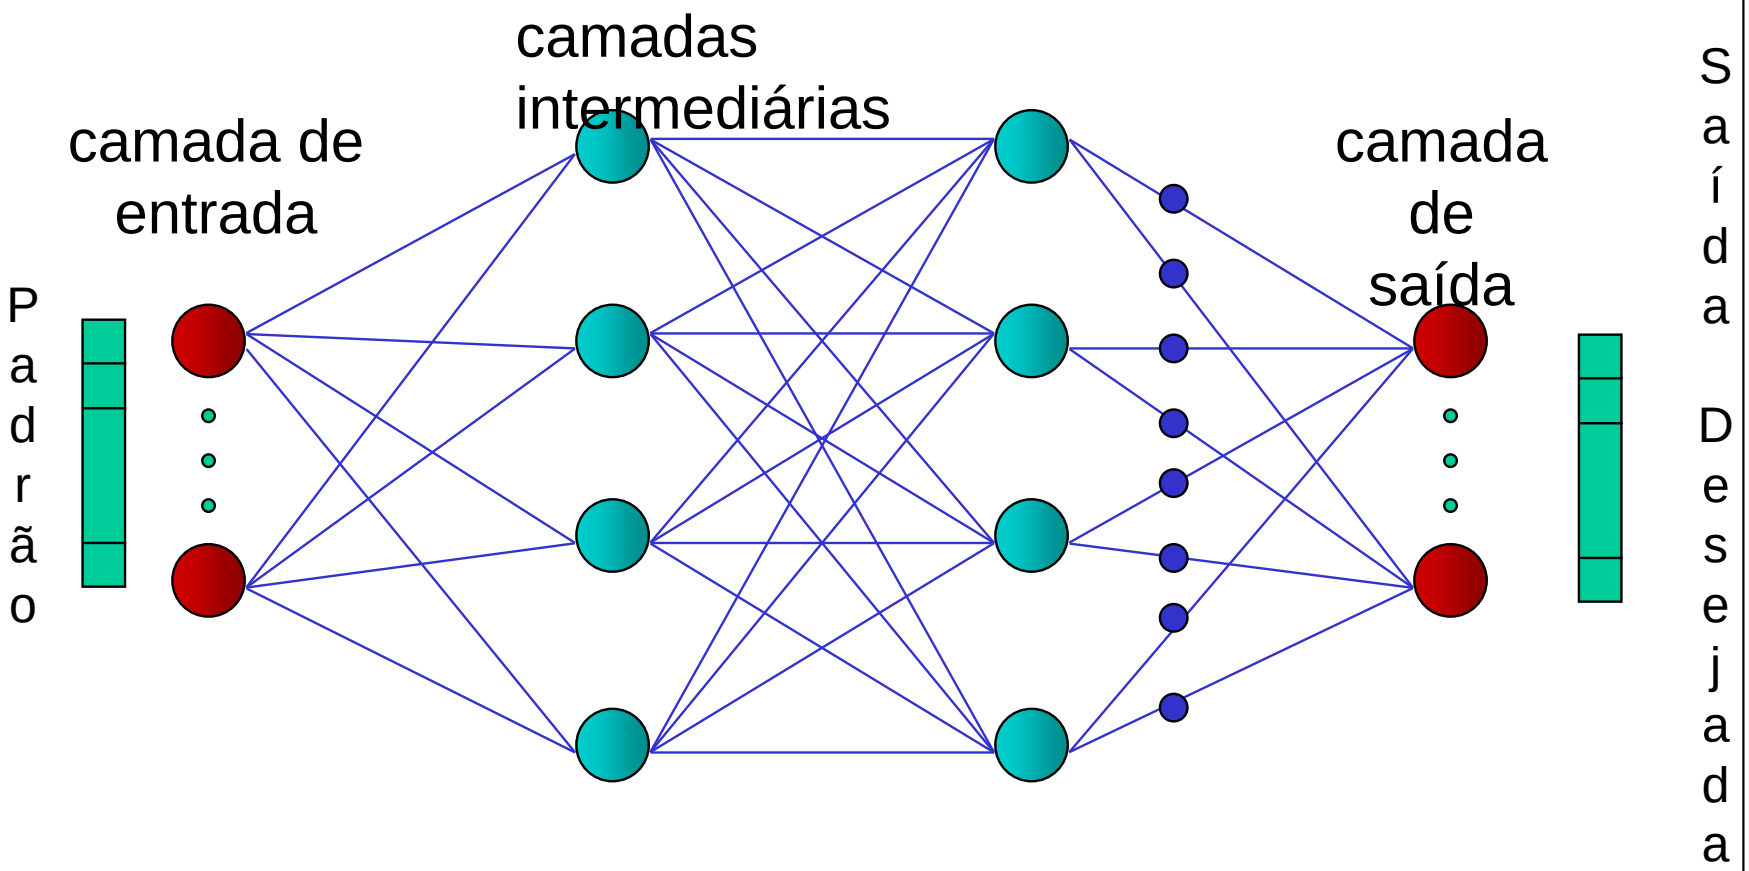
RNA - Aprendizado



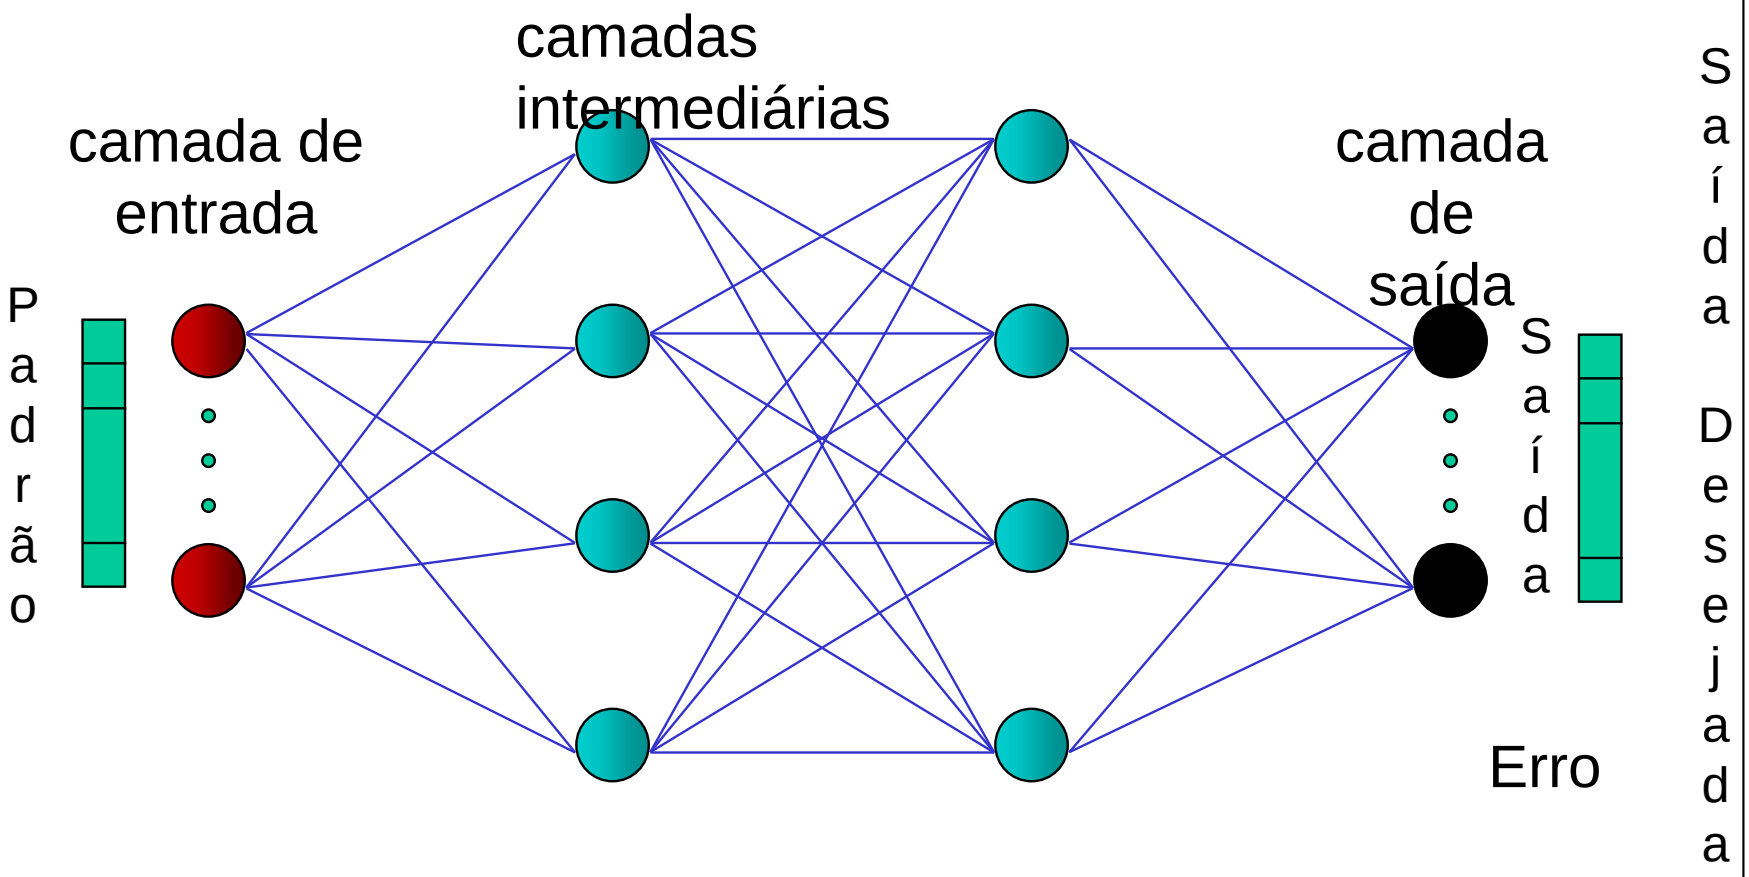
RNA - Aprendizado



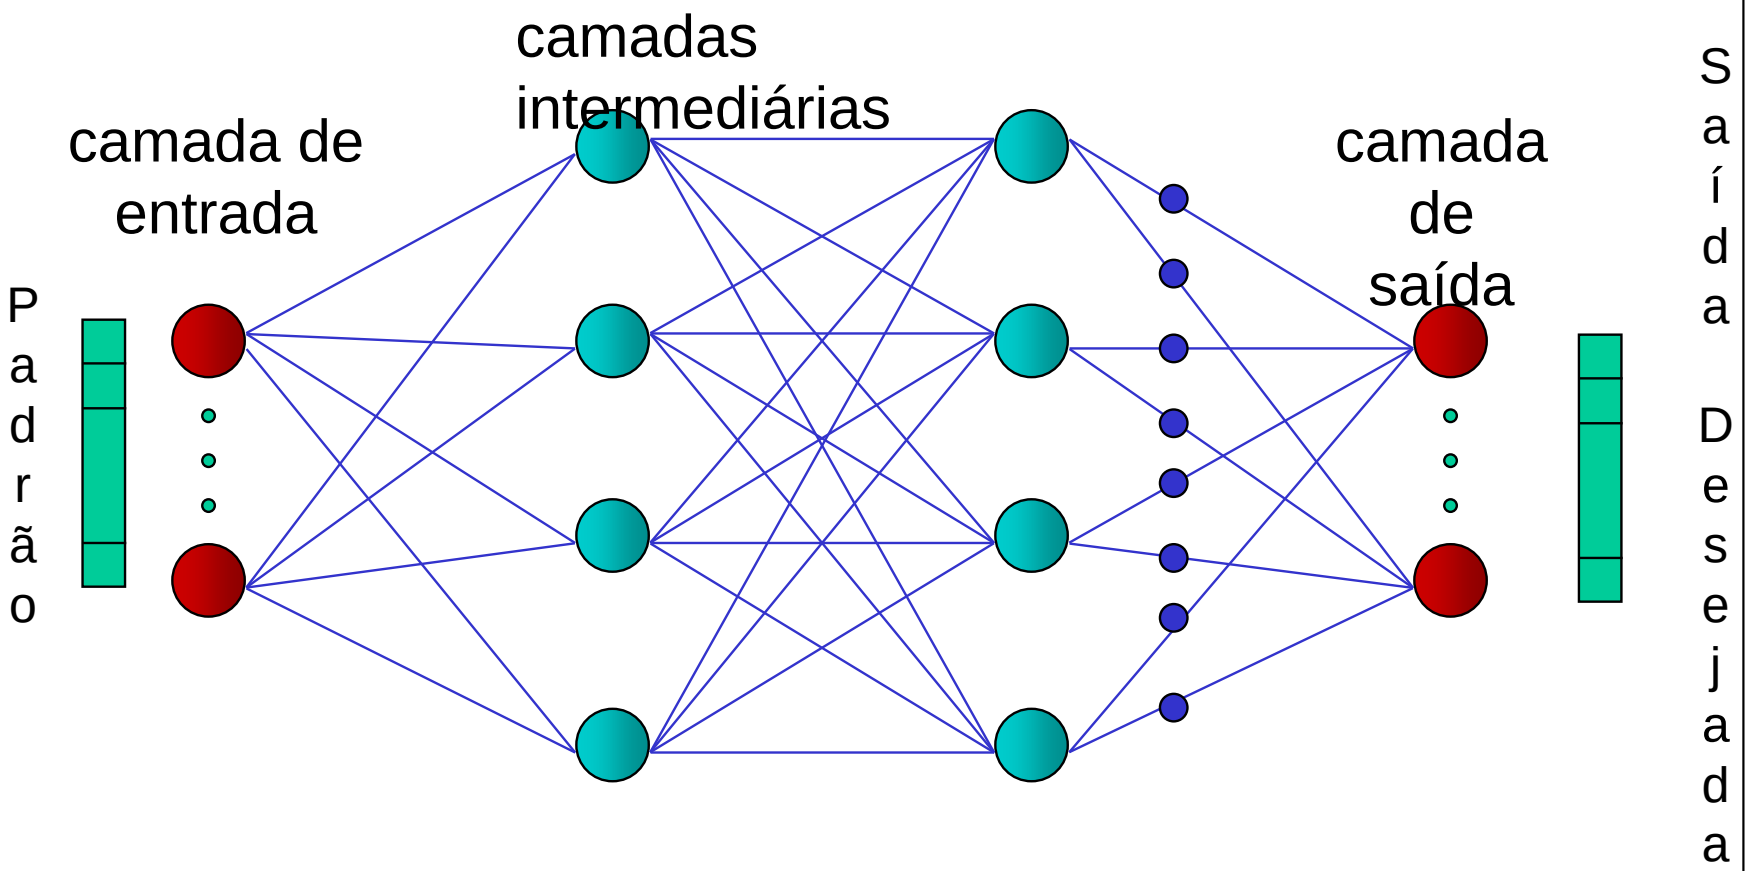
RNA - Aprendizado



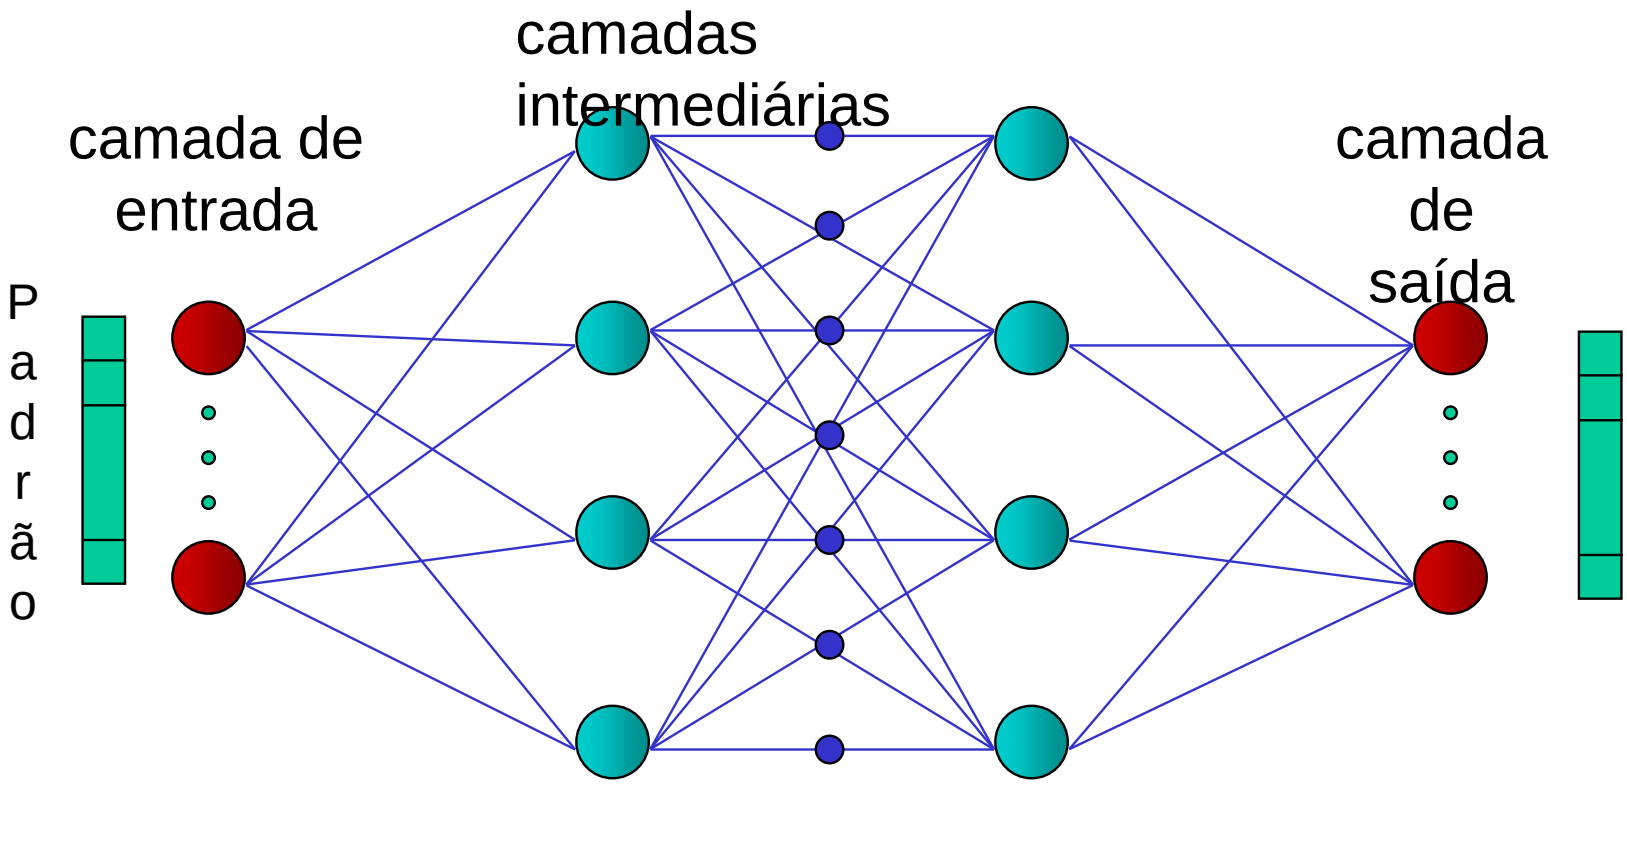
RNA - Aprendizado



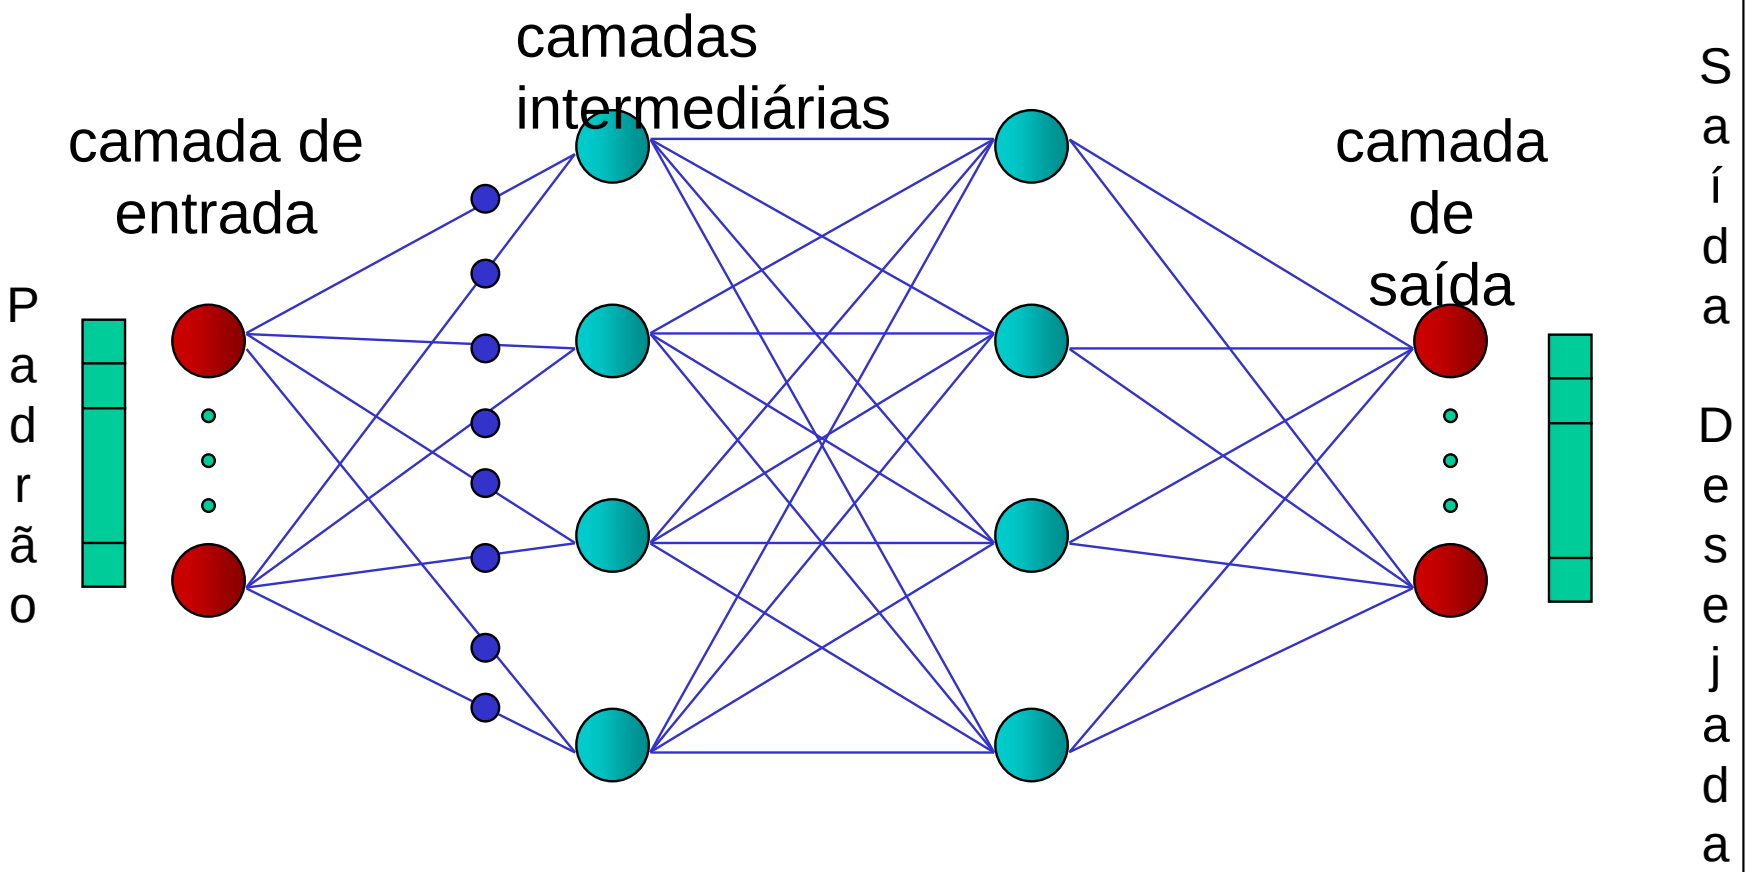
RNA - Aprendizado



RNA - Aprendizado

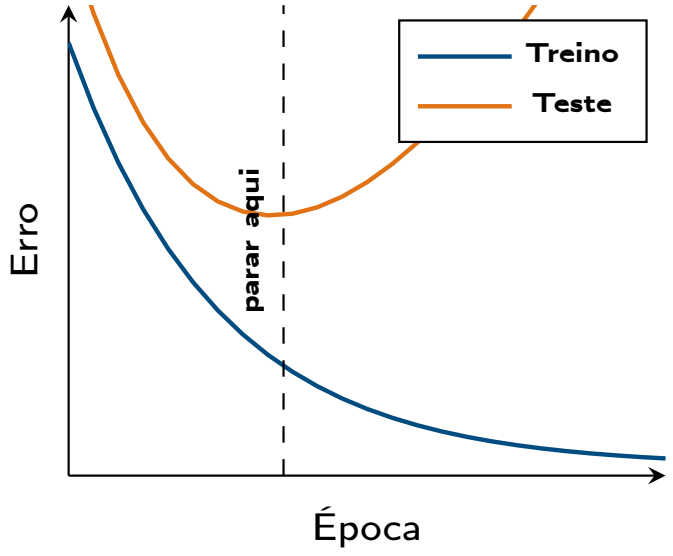


RNA - Aprendizado



Overfitting em redes neurais

- **Parada antecipada**: interrompa quando o erro de teste deixa de cair.
- **Regularização L2** nos pesos.
- ***Dropout***: desliga neurônios aleatoriamente no treino.
- **Aumento de dados**.



Redes na prática

```python
import numpy as np
from sklearn.neural_network import MLPClassifier

X = np.array([[0,0],[0,1],[1,0],[1,1]])
y = np.array([0, 1, 1, 0])              # XOR

mlp = MLPClassifier(hidden_layer_sizes=(4,), activation="tanh",
                    solver="lbfgs", max_iter=2000, random_state=0)
mlp.fit(X, y)
print(mlp.predict(X))                   # [0 1 1 0]
```

Para redes maiores, use PyTorch ou Keras, que treinam em GPU.



Arquiteturas atuais

Arquitetura	**Dados típicos**	**Exemplo de uso**
Convolucional (CNN)	imagens (ver Aula 3)	diagnóstico por imagem
Recorrente e LSTM	sequências	séries temporais
Transformer	texto, imagem, áudio	modelos de linguagem
Difusão	imagens e vídeo	geração de imagens

Limitações: grande consumo de dados e energia, pouca interpretabilidade e respostas plausíveis porém incorretas.



Aprendizado sem rótulos

Dado apenas $X = \{x_1, \ldots, x_n\} \subset \mathbb{R}^d$, buscamos **estrutura** nos dados.

- Agrupamento (*clustering*).
- Redução de dimensionalidade.
- Detecção de anomalias.



Figura: Amostras sem rótulo agrupadas por semelhança.

Para refletir

Como saber se um agrupamento é bom, se não há resposta correta?

K-Means

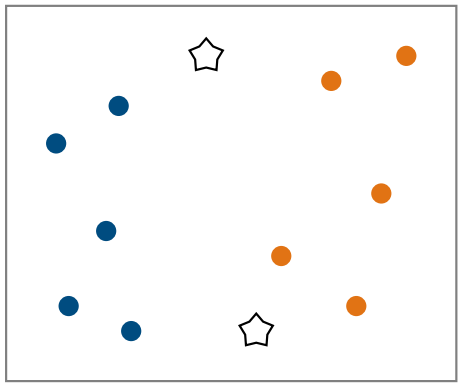
Particiona os dados em k grupos que minimizam a soma dos quadrados intragrupo:

$$\mathcal{J} = \sum_{j=1}^{k} \sum_{x \in C_j} \|x - \mu_j\|^2.$$

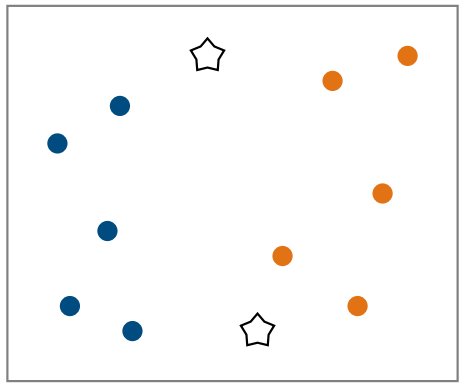
1. Escolha k centróides iniciais.
2. Atribua cada ponto ao centróide mais próximo.
3. Recalcule cada centróide como a média do seu grupo.
4. Repita até as atribuições não mudarem.



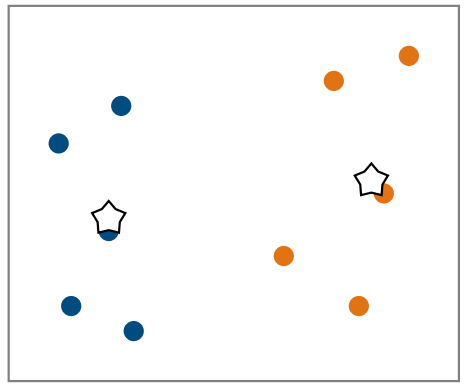
K-Means em três passos



1. Início



2. Atribuir



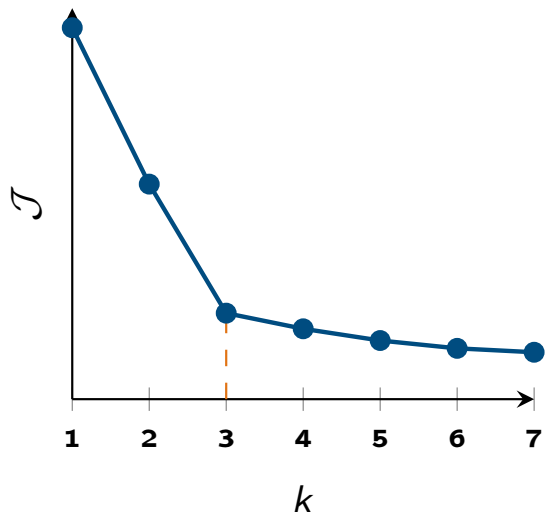
3. Atualizar

Limitações e escolha de k

- O resultado depende da inicialização, e por isso se usa *k-means++*.
- Assume grupos aproximadamente esféricos.
- Exige atributos na mesma escala.
- **Escolha de** k: método do cotovelo e coeficiente de silhueta

$$s = \frac{b - a}{\max(a, b)}$$

a: distância média ao próprio grupo. b: distância média ao grupo mais próximo.

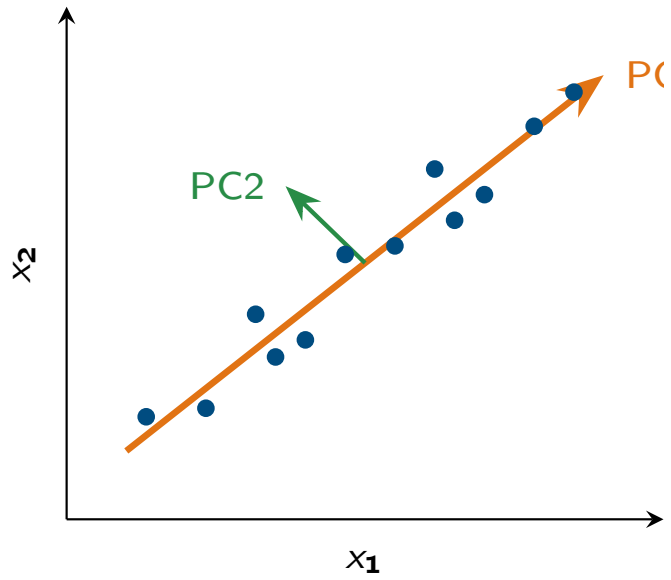


Curva ilustrativa. O cotovelo sugere $k = 3$.

Análise de Componentes Principais (PCA)

Projeta os dados nas direções de **maior variância**.

1. Centralize os dados.
2. Calcule a matriz de covariância Σ.
3. Obtenha autovalores e autovetores, $\Sigma v = \lambda v$.
4. Projete nos k autovetores de maiores autovalores.



PCA: exemplo resolvido

Com $\Sigma = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$, os autovalores são $\lambda_1 = 3$ e $\lambda_2 = 1$, com autovetores

$$v_1 = \frac{1}{\sqrt{2}}(1, 1), \qquad v_2 = \frac{1}{\sqrt{2}}(1, -1).$$

A primeira componente explica $\dfrac{3}{3+1} = 75\%$ da variância total.

Usos: visualizar dados em duas dimensões, remover redundância e acelerar outros modelos. Para visualização não linear, existem t-SNE e UMAP.

Para refletir

Que informação se perde ao manter apenas PC1?



Exercício

Aplique o K-Means ($k = 2$) aos pontos $1, 3, 4, 10$ com centróides iniciais $\mu_1 = 1$ e $\mu_2 = 10$.

Resposta

Atribuição: $C_1 = \{1, 3, 4\}$ e $C_2 = \{10\}$. Novos centróides: $\mu_1 = 8/3 \approx 2{,}67$ e $\mu_2 = 10$. A atribuição se repete, então o algoritmo convergiu.



Exercício

Aplique o K-Means ($k = 2$) aos pontos $1, 3, 4, 10$ com centróides iniciais $\mu_1 = 1$ e $\mu_2 = 10$.

Resposta

Atribuição: $C_1 = \{1, 3, 4\}$ e $C_2 = \{10\}$. Novos centróides: $\mu_1 = 8/3 \approx 2{,}67$ e $\mu_2 = 10$. A atribuição se repete, então o algoritmo convergiu.



Responsabilidade ao usar ML

- **Viés nos dados** se transforma em viés nas decisões. Em 2018, a Reuters relatou que a Amazon abandonou uma ferramenta de triagem de currículos que penalizava candidatas.
- **Privacidade**: dados pessoais exigem base legal (LGPD) e proteção.
- **Explicabilidade**: decisões de alto impacto precisam de justificativa.
- **Mudança de contexto**: modelos degradam quando o mundo muda.

? Para refletir

Quem responde quando um modelo erra em uma decisão sobre pessoas?



Resumo da aula

Tema	**Ideia central**	**Pergunta-chave**
Supervisionado	aprender $x \mapsto y$ com exemplos	o modelo generaliza?
Teste	separar treino e teste	há vazamento de dados?
Classificação	matriz de confusão e métricas	qual erro custa mais?
Regressão	mínimos quadrados e resíduos	as suposições valem?
Redes neurais	camadas, perda e gradiente	o que aprendeu, e com que custo?
Não supervisionado	agrupar e reduzir dimensões	a estrutura faz sentido?



Referências I


Russell, S. e Norvig, P. (2021). *Artificial Intelligence: A Modern Approach*. 4ª ed. Pearson.


Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. 3ª ed. O'Reilly.


Goodfellow, I., Bengio, Y. e Courville, A. (2016). *Deep Learning*. MIT Press.


Chollet, F. (2021). *Deep Learning with Python*. 2ª ed. Manning.


James, G. et al. (2021). *An Introduction to Statistical Learning*. 2ª ed. Springer.


Mitchell, T. (1997). *Machine Learning*. McGraw-Hill.


McCulloch, W. e Pitts, W. (1943). A logical calculus of the ideas immanent in nervous activity. *Bulletin of Mathematical Biophysics*, 5.


Rosenblatt, F. (1958). The perceptron. *Psychological Review*, 65(6).



Referências II


Rumelhart, D., Hinton, G. e Williams, R. (1986). Learning representations by back-propagating errors. *Nature*, 323.


Vaswani, A. et al. (2017). Attention is all you need. *NeurIPS*.





Machine Learning

Professor: Elton Sarmanho[1]
E-mail: eltonss@ufpa.br





[1]Faculdade de Sistemas de Informação - UFPA/CUNTINS

23 de outubro de 2026