Mineração de Dados: Conceitos e Aplicações

Módulo 7: Aplicações

Prof. Elton Sarmanho[1]
eltonss@ufpa.br

[1]Faculdade de Sistemas de Informação - UFPA Campus Cametá

13 de outubro de 2026

github.com/eltonsarmanho Elton Sarmanho

Roteiro da Aula

- Por que RAG?
  - Limitações dos LLMs
  - Arquitetura e Paradigmas
- Divisão dos Dados
  - Carregamento de Documentos
  - Chunking
- Embeddings
  - Representação Vetorial Semântica
  - Modelos de Embedding

Roteiro da Aula

- Banco de Dados Vetorial
- Busca Semântica e Recuperação
  - Semantic Search e MMR
  - Combinando Contexto com o LLM
- Avaliação de Sistemas RAG
- Extração de Dados
  - Palavras-chave e Tópicos
  - Tendências e Relações
- Estudo de Caso: Chatbot RAG
- Qualidade, Segurança e Tendências
  - Tendências de Pesquisa

Limitações dos LLMs “Puros”

Problemas

- **Alucinação:** gera texto plausível, porém factualmente incorreto
- **Conhecimento desatualizado:** *knowledge cutoff* do treinamento
- **Sem dados privados:** não conhece documentos internos, currículos, artigos específicos
- **Falta de rastreabilidade:** não cita fontes verificáveis

Analogia

Um LLM “puro” é um estudante fazendo prova **de memória**.

Um sistema RAG é um estudante fazendo prova **de consulta**: busca nas anotações antes de responder.

Limitações dos LLMs "Puros"

Problemas

- **Alucinação:** gera texto plausível, porém factualmente incorreto
- **Conhecimento desatualizado:** *knowledge cutoff* do treinamento
- **Sem dados privados:** não conhece documentos internos, currículos, artigos específicos
- **Falta de rastreabilidade:** não cita fontes verificáveis

Analogia

Um LLM "puro" é um estudante fazendo prova **de memória**.

Um sistema RAG é um estudante fazendo prova **de consulta**: busca nas anotações antes de responder.

RAG como consulta a evidências



Figura: Um *agent* consulta documentos do acervo antes de formular uma resposta.

Reflexão

Qual informação da fonte precisa acompanhar a resposta para que o estudante possa conferi-la?

Retrieval-Augmented Generation (RAG)

Definição (Lewis et al., 2020)

Arquitetura que combina um mecanismo de **recuperação de informação** sobre uma base externa com um modelo de **geração de linguagem**, condicionando a resposta a evidências recuperadas dinamicamente.

$$p(y \mid x) \approx \sum_{z \in \mathcal{Z}_k(x)} p_\eta(z \mid x)\, p_\theta(y \mid x, z)$$

$\mathcal{Z}_k(x)$: k evidências recuperadas para a pergunta x; p_η: *retriever*; p_θ: gerador; z: evidência.

RAG e *fine-tuning* resolvem problemas diferentes. RAG atualiza conhecimento e permite atribuição de fontes; *fine-tuning* altera comportamento ou adapta o modelo a uma tarefa.

Retrieval-Augmented Generation (RAG)

Definição (Lewis et al., 2020)

Arquitetura que combina um mecanismo de **recuperação de informação** sobre uma base externa com um modelo de **geração de linguagem**, condicionando a resposta a evidências recuperadas dinamicamente.

$$p(y \mid x) \approx \sum_{z \in \mathcal{Z}_k(x)} p_\eta(z \mid x)\, p_\theta(y \mid x, z)$$

$\mathcal{Z}_k(x)$: k evidências recuperadas para a pergunta x; p_η: *retriever*; p_θ: gerador; z: evidência.

RAG e *fine-tuning* resolvem problemas diferentes. RAG atualiza conhecimento e permite atribuição de fontes; *fine-tuning* altera comportamento ou adapta o modelo a uma tarefa.

Retrieval-Augmented Generation (RAG)

Definição (Lewis et al., 2020)

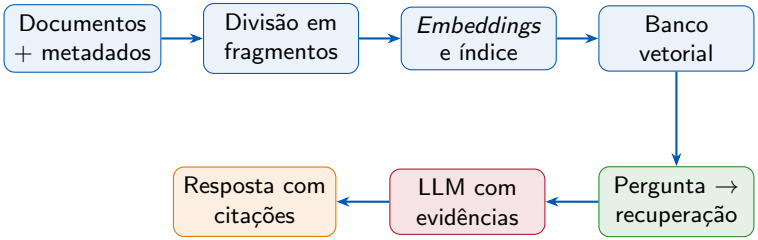
Arquitetura que combina um mecanismo de **recuperação de informação** sobre uma base externa com um modelo de **geração de linguagem**, condicionando a resposta a evidências recuperadas dinamicamente.

$$p(y \mid x) \approx \sum_{z \in \mathcal{Z}_k(x)} p_\eta(z \mid x)\, p_\theta(y \mid x, z)$$

$\mathcal{Z}_k(x)$: k evidências recuperadas para a pergunta x; p_η: *retriever*; p_θ: gerador; z: evidência.

RAG e *fine-tuning* resolvem problemas diferentes. RAG atualiza conhecimento e permite atribuição de fontes; *fine-tuning* altera comportamento ou adapta o modelo a uma tarefa.

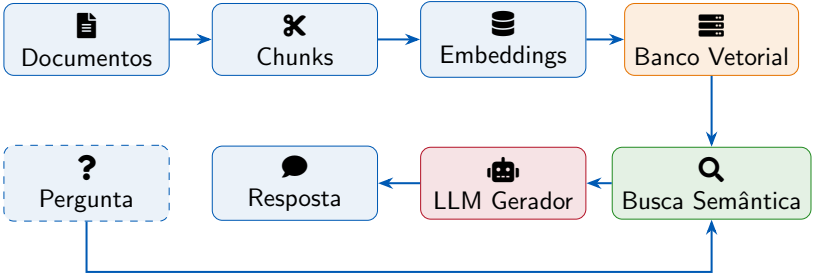
Pipeline RAG: Visão Geral



Reflexão

Em que etapa uma referência de página ou seção deve acompanhar o fragmento para que a resposta possa ser auditada?

Pipeline RAG: Diagrama Esquemático



Paradigmas de RAG (Gao et al., 2024)

Naive RAG

Pipeline direto: indexar → recuperar → gerar. É um bom ponto de partida, mas pode trazer contexto redundante ou insuficiente.

Advanced RAG

Adiciona reescrita de consultas, *re-ranking* e compressão de contexto antes/depois da recuperação.

Modular RAG

Arquitetura flexível com módulos intercambiáveis: roteamento, memória, busca híbrida, iteração múltipla.

Paradigmas de RAG (Gao et al., 2024)

Naive RAG

Pipeline direto: indexar → recuperar → gerar. É um bom ponto de partida, mas pode trazer contexto redundante ou insuficiente.

Advanced RAG

Adiciona reescrita de consultas, *re-ranking* e compressão de contexto antes/depois da recuperação.

Modular RAG

Arquitetura flexível com módulos intercambiáveis: roteamento, memória, busca híbrida, iteração múltipla.

Paradigmas de RAG (Gao et al., 2024)

Naive RAG

Pipeline direto: indexar → recuperar → gerar. É um bom ponto de partida, mas pode trazer contexto redundante ou insuficiente.

Advanced RAG

Adiciona reescrita de consultas, *re-ranking* e compressão de contexto antes/depois da recuperação.

Modular RAG

Arquitetura flexível com módulos intercambiáveis: roteamento, memória, busca híbrida, iteração múltipla.

Document Loading: Carregamento de Documentos

Dados Estruturados

Tabelas, planilhas, bancos relacionais e CSV/JSON costumam seguir um esquema definido.

Dados Não Estruturados

PDFs, páginas web, áudio, vídeo e e-mails exigem extração e *parsers* adequados.

Importante

Preserve metadados como página, seção, autor e data. Eles permitem localizar e citar a fonte na resposta final.

Document Loading: Carregamento de Documentos

Dados Estruturados

Tabelas, planilhas, bancos relacionais e CSV/JSON costumam seguir um esquema definido.

Dados Não Estruturados

PDFs, páginas web, áudio, vídeo e e-mails exigem extração e *parsers* adequados.

Importante

Preserve metadados como página, seção, autor e data. Eles permitem localizar e citar a fonte na resposta final.

Por que Dividir Documentos em *Chunks*?

Motivação

Mesmo quando cabem na janela de contexto, documentos inteiros tornam a recuperação menos seletiva. Fragmentos bem formados ligam uma evidência específica à pergunta.

Divisão Mal Feita

"O novo modelo da Renault é o Duster, possui 110 cavalos..." dividido ingenuamente em:

- `"O novo modelo da Renault é"`
- `"o Duster, possui 110"`
- `"cavalos de potência..."`

Nenhum fragmento isolado responde "Qual o preço do Duster?"

Por que Dividir Documentos em *Chunks*?

Motivação

Mesmo quando cabem na janela de contexto, documentos inteiros tornam a recuperação menos seletiva. Fragmentos bem formados ligam uma evidência específica à pergunta.

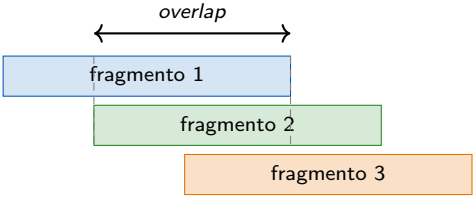
Divisão Mal Feita

"O novo modelo da Renault é o Duster, possui 110 cavalos..." dividido ingenuamente em:

- `"O novo modelo da Renault é"`
- `"o Duster, possui 110"`
- `"cavalos de potência..."`

Nenhum fragmento isolado responde "Qual o preço do Duster?"

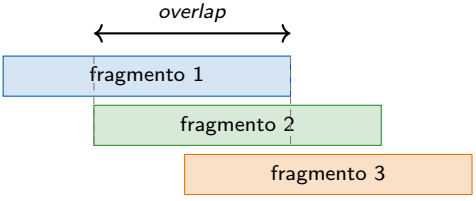
chunk_size e chunk_overlap



- **chunk_size:** tamanho do fragmento (caracteres/*tokens*)
- **chunk_overlap:** sobreposição entre fragmentos consecutivos, evita cortar informação na fronteira

Fragmentos muito curtos perdem relações locais. Fragmentos muito longos aumentam ruído e custo. Ajuste com consultas reais do acervo.

chunk_size e chunk_overlap



- **chunk_size:** tamanho do fragmento (caracteres/*tokens*)
- **chunk_overlap:** sobreposição entre fragmentos consecutivos, evita cortar informação na fronteira

Fragmentos muito curtos perdem relações locais. Fragmentos muito longos aumentam ruído e custo. Ajuste com consultas reais do acervo.

Estratégias de Divisão de Texto

Estratégia	Funcionamento	Uso
Fixed-size	Corta a cada *N* unidades, com pouca noção de estrutura	Linhas ou registros uniformes
Recursivo	Tenta preservar parágrafos e frases antes de cortar	Ponto de partida para prosa
Estrutural	Usa sintaxe do formato (Markdown/HTML/código)	Doc. técnica, código
Semântico	Agrupa sentenças por similaridade de *embedding*	Textos longos e heterogêneos

Boas Práticas

Meça o tamanho em *tokens* do modelo escolhido. Comece com fragmentos que preservem uma ideia completa e teste tamanho, sobreposição e k com perguntas representativas. Mantenha metadados por fragmento.

Estratégias de Divisão de Texto

Estratégia	Funcionamento	Uso
Fixed-size	Corta a cada *N* unidades, com pouca noção de estrutura	Linhas ou registros uniformes
Recursivo	Tenta preservar parágrafos e frases antes de cortar	Ponto de partida para prosa
Estrutural	Usa sintaxe do formato (Markdown/HTML/código)	Doc. técnica, código
Semântico	Agrupa sentenças por similaridade de *embedding*	Textos longos e heterogêneos

Boas Práticas

Meça o tamanho em *tokens* do modelo escolhido. Comece com fragmentos que preservem uma ideia completa e teste tamanho, sobreposição e k com perguntas representativas. Mantenha metadados por fragmento.

O que é um Embedding?

Definição

Representação vetorial densa $\mathbf{v} \in \mathbb{R}^d$ de um texto, onde proximidade **geométrica** reflete proximidade **semântica**.

Exemplo

"desistência de estudantes" e "evasão escolar" $\rightarrow$ vetores próximos, mesmo sem palavras em comum.

Por que importa para RAG?

Permite superar a busca por palavra-chave: recupera por **significado**, não por correspondência literal.

O que é um Embedding?

Definição

Representação vetorial densa $\mathbf{v} \in \mathbb{R}^d$ de um texto, onde proximidade **geométrica** reflete proximidade **semântica**.

Exemplo

"desistência de estudantes" e "evasão escolar" $\rightarrow$ vetores próximos, mesmo sem palavras em comum.

Por que importa para RAG?

Permite superar a busca por palavra-chave: recupera por **significado**, não por correspondência literal.

O que é um Embedding?

Definição

Representação vetorial densa $\mathbf{v} \in \mathbb{R}^d$ de um texto, onde proximidade **geométrica** reflete proximidade **semântica**.

Exemplo

"desistência de estudantes" e "evasão escolar" $\rightarrow$ vetores próximos, mesmo sem palavras em comum.

Por que importa para RAG?

Permite superar a busca por palavra-chave: recupera por **significado**, não por correspondência literal.

Evolução: de TF-IDF a Embeddings Contextuais

Geração	Características
TF-IDF	Vetores esparsos por frequência; sem sinônimos
Word2Vec/GloVe (2013–14)	Vetores densos estáticos por palavra
BERT (2018)	Vetores contextuais (dependem da frase)
Modelos de sentença (2019+)	Um vetor por frase/parágrafo, otimizado para similaridade

Similaridade de Cosseno

Fórmula

$$\text{sim}_{\cos}(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \, \|\mathbf{v}\|} \in [-1, 1]$$

Vetores normalizados

Quando $\|\mathbf{u}\| = \|\mathbf{v}\| = 1$, a similaridade de cosseno é o produto escalar $\mathbf{u} \cdot \mathbf{v}$. Essa propriedade simplifica muitos índices vetoriais.

sim("gosto de cachorros", "gosto de animais") $\gg$ sim("gosto de cachorros", "tempo está ruim")

Similaridade de Cosseno

Fórmula

$$\text{sim}_{\cos}(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \, \|\mathbf{v}\|} \in [-1, 1]$$

Vetores normalizados

Quando $\|\mathbf{u}\| = \|\mathbf{v}\| = 1$, a similaridade de cosseno é o produto escalar $\mathbf{u} \cdot \mathbf{v}$. Essa propriedade simplifica muitos índices vetoriais.

sim("gosto de cachorros", "gosto de animais") $\gg$ sim("gosto de cachorros", "tempo está ruim")

Similaridade de Cosseno

Fórmula

$$\text{sim}_{\cos}(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \, \|\mathbf{v}\|} \in [-1, 1]$$

Vetores normalizados

Quando $\|\mathbf{u}\| = \|\mathbf{v}\| = 1$, a similaridade de cosseno é o produto escalar $\mathbf{u} \cdot \mathbf{v}$. Essa propriedade simplifica muitos índices vetoriais.

sim("gosto de cachorros", "gosto de animais") $\gg$ sim("gosto de cachorros", "tempo está ruim")

Modelos de Embedding Disponíveis

Modelo	Provedor	Observação
text-embedding-3-large	OpenAI	Alta precisão, dimensão configurável, pago
Modelos multimodais	Diversos	Podem representar mais de um tipo de dado, conforme o modelo e a API
BGE-M3 / Jina E5 / GTE	BAAI / Jina AI Microsoft / Alibaba	Abertos, executáveis localmente *Baseline* amplamente usado

MTEB: Massive Text Embedding Benchmark

Um dos principais *benchmarks* públicos para comparar modelos de *embedding*. Use resultados compatíveis com idioma, domínio e tipo de consulta. ⚠ Use o mesmo modelo para indexar e consultar.

Modelos de Embedding Disponíveis

Modelo	Provedor	Observação
text-embedding-3-large	OpenAI	Alta precisão, dimensão configurável, pago
Modelos multimodais	Diversos	Podem representar mais de um tipo de dado, conforme o modelo e a API
BGE-M3 / Jina E5 / GTE	BAAI / Jina AI Microsoft / Alibaba	Abertos, executáveis localmente *Baseline* amplamente usado

MTEB: Massive Text Embedding Benchmark

Um dos principais *benchmarks* públicos para comparar modelos de *embedding*. Use resultados compatíveis com idioma, domínio e tipo de consulta. ⚠ Use o mesmo modelo para indexar e consultar.

Banco de Dados Vetorial (Vector Store)

Definição

Sistema especializado em indexar e consultar eficientemente grandes coleções de vetores, retornando os k mais próximos (k-NN) de uma consulta.

O Problema da Escala

Busca exata k-NN custa $O(n \cdot d)$ por consulta. Em coleções grandes, índices **ANN** (*Approximate Nearest Neighbors*) negociam uma pequena perda de *recall* por menor latência.

- **HNSW:** grafo hierárquico de vizinhança (Malkov & Yashunin, 2018), com boa latência e maior uso de memória
- **IVF:** particiona o espaço em *clusters* (K-Means)
- **PQ:** comprime vetores, reduz uso de memória

Banco de Dados Vetorial (Vector Store)

Definição

Sistema especializado em indexar e consultar eficientemente grandes coleções de vetores, retornando os k mais próximos (k-NN) de uma consulta.

O Problema da Escala

Busca exata k-NN custa $O(n \cdot d)$ por consulta. Em coleções grandes, índices **ANN** (*Approximate Nearest Neighbors*) negociam uma pequena perda de *recall* por menor latência.

- **HNSW:** grafo hierárquico de vizinhança (Malkov & Yashunin, 2018), com boa latência e maior uso de memória
- **IVF:** particiona o espaço em *clusters* (K-Means)
- **PQ:** comprime vetores, reduz uso de memória

Banco de Dados Vetorial (Vector Store)

Definição

Sistema especializado em indexar e consultar eficientemente grandes coleções de vetores, retornando os k mais próximos (k-NN) de uma consulta.

O Problema da Escala

Busca exata k-NN custa $O(n \cdot d)$ por consulta. Em coleções grandes, índices **ANN** (*Approximate Nearest Neighbors*) negociam uma pequena perda de *recall* por menor latência.

- **HNSW:** grafo hierárquico de vizinhança (Malkov & Yashunin, 2018), com boa latência e maior uso de memória
- **IVF:** particiona o espaço em *clusters* (K-Means)
- **PQ:** comprime vetores, reduz uso de memória

Comparação de Soluções

Solução	Escala Ideal	Persistência	Observação
Chroma	Protótipos e aplicações locais	Disponível	API simples para experimentar
FAISS	Índices embarcados	A cargo da aplicação	Biblioteca rápida para busca vetorial
Pinecone, Weaviate, Milvus	Serviços ou clusters	Depende da implantação	Recursos operacionais e de escalabilidade variam
pgvector	Integra c/ dados relacionais	Nativa PostgreSQL	Combina busca vetorial + SQL

Recomendação

Escolha pelo volume, filtros por metadados, latência, custo e requisitos de operação. Compare com dados e consultas semelhantes aos do projeto.

Comparação de Soluções

Solução	Escala Ideal	Persistência	Observação
Chroma	Protótipos e aplicações locais	Disponível	API simples para experimentar
FAISS	Índices embarcados	A cargo da aplicação	Biblioteca rápida para busca vetorial
Pinecone, Weaviate, Milvus	Serviços ou clusters	Depende da implantação	Recursos operacionais e de escalabilidade variam
pgvector	Integra c/ dados relacionais	Nativa PostgreSQL	Combina busca vetorial + SQL

Recomendação

Escolha pelo volume, filtros por metadados, latência, custo e requisitos de operação. Compare com dados e consultas semelhantes aos do projeto.

Busca Semântica (*Semantic Search*)

Definição

Recupera os k documentos com maior similaridade de cosseno ao *embedding* da consulta, por **significado**, não apenas por palavra-chave.

Vantagens

- Simples
- Baixo custo
- Ótima p/ perguntas factuais

Limitações

- Pode retornar documentos redundantes
- Sem garantia de diversidade

Busca Semântica (*Semantic Search*)

Definição

Recupera os k documentos com maior similaridade de cosseno ao *embedding* da consulta, por **significado**, não apenas por palavra-chave.

Vantagens

- Simples
- Baixo custo
- Ótima p/ perguntas factuais

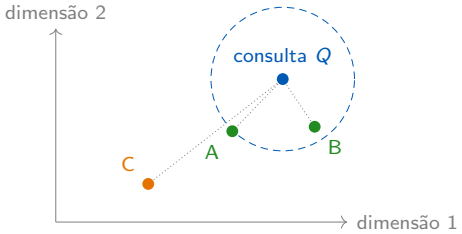
Limitações

- Pode retornar documentos redundantes
- Sem garantia de diversidade

MMR: Maximal Marginal Relevance

Fórmula (Carbonell & Goldstein, 1998)

$$\text{MMR} = \arg \max_{D_i \in R \setminus S} \left[\lambda \cdot \text{sim}(D_i, Q) - (1 - \lambda) \cdot \max_{D_j \in S} \text{sim}(D_i, D_j) \right]$$



A e B são relevantes, mas redundantes. C é menos próximo de Q, porém acrescenta diversidade.

$\lambda \to 1$: prioriza relevância.
$\lambda \to 0$: prioriza diversidade.

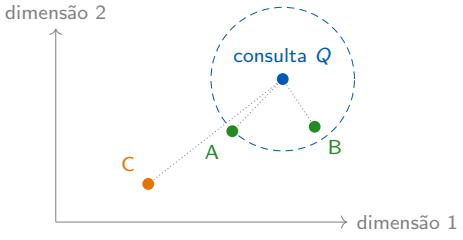
Quando usar

Semantic Search: perguntas factuais.
MMR: perguntas exploratórias, evita redundância.

MMR: Maximal Marginal Relevance

Fórmula (Carbonell & Goldstein, 1998)

$$\text{MMR} = \arg \max_{D_i \in R \setminus S} \left[\lambda \cdot \text{sim}(D_i, Q) - (1 - \lambda) \cdot \max_{D_j \in S} \text{sim}(D_i, D_j) \right]$$



A e B são relevantes, mas redundantes. C é menos próximo de Q, porém acrescenta diversidade.

$\lambda \to 1$: prioriza relevância.
$\lambda \to 0$: prioriza diversidade.

Quando usar

Semantic Search: perguntas factuais.
MMR: perguntas exploratórias, evita redundância.

Busca Híbrida

Densa + Esparsa

Combina recuperação por *embeddings* (densa) com BM25 (esparsa e lexical). Os resultados podem ser fundidos por ranking ou reordenados por um *reranker*.

Quando usar

Consultas com termos técnicos exatos (siglas, códigos, nomes próprios) que a busca semântica pura pode não priorizar.

Busca Híbrida

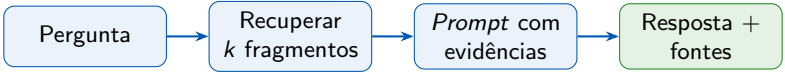
Densa + Esparsa

Combina recuperação por *embeddings* (densa) com BM25 (esparsa e lexical). Os resultados podem ser fundidos por ranking ou reordenados por um *reranker*.

Quando usar

Consultas com termos técnicos exatos (siglas, códigos, nomes próprios) que a busca semântica pura pode não priorizar.

Pipeline RetrievalQA

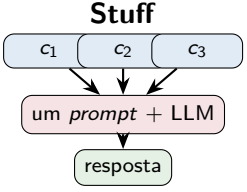


Pergunta $\rightarrow$ consulta ao banco vetorial $\rightarrow$ fragmentos relevantes $\rightarrow$ LLM $\rightarrow$ resposta.

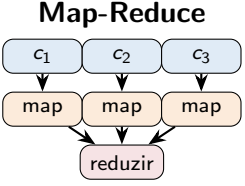
Estratégias de Combinação: Stuff, Map-Reduce, Refine

Estratégia	Funcionamento	Compromisso
Stuff	Concatena todos os fragmentos em um único *prompt*	Simples, limitada pela janela de contexto
Map-Reduce	Resposta parcial por fragmento, depois combina	Escala, mais custo/latência
Refine	Refina resposta iterativamente a cada fragmento	Mais contexto, sequencial e lenta

Stuff vs. Map-Reduce: Diagramas



Simples, limitado pelo contexto.



Escala melhor, com mais chamadas ao modelo.

RAGAS: Métricas de Avaliação

Duas Frentes de Falha

Um RAG pode falhar na **recuperação** (documentos errados) ou na **geração** (resposta mal formulada mesmo com contexto correto).

Métrica	Definição
Context Precision	Proporção do contexto recuperado que é relevante (retriever)
Context Recall	Proporção da informação necessária que foi recuperada (retriever)
Faithfulness	Afirmações da resposta sustentadas pelo contexto (gerador)
Answer Relevancy	O quanto a resposta aborda a pergunta (gerador)

Diagnóstico

Precision/Recall baixos → ajustar *chunking*/*embedding*/busca. Faithfulness baixa → problema no LLM/*prompt*.

RAGAS: Métricas de Avaliação

Duas Frentes de Falha

Um RAG pode falhar na **recuperação** (documentos errados) ou na **geração** (resposta mal formulada mesmo com contexto correto).

Métrica	Definição
Context Precision	Proporção do contexto recuperado que é relevante (retriever)
Context Recall	Proporção da informação necessária que foi recuperada (retriever)
Faithfulness	Afirmações da resposta sustentadas pelo contexto (gerador)
Answer Relevancy	O quanto a resposta aborda a pergunta (gerador)

Diagnóstico

Precision/Recall baixos → ajustar *chunking*/*embedding*/busca. Faithfulness baixa → problema no LLM/*prompt*.

RAGAS: Métricas de Avaliação

Duas Frentes de Falha

Um RAG pode falhar na **recuperação** (documentos errados) ou na **geração** (resposta mal formulada mesmo com contexto correto).

Métrica	Definição
Context Precision	Proporção do contexto recuperado que é relevante (retriever)
Context Recall	Proporção da informação necessária que foi recuperada (retriever)
Faithfulness	Afirmações da resposta sustentadas pelo contexto (gerador)
Answer Relevancy	O quanto a resposta aborda a pergunta (gerador)

Diagnóstico

Precision/Recall baixos $\rightarrow$ ajustar *chunking*/*embedding*/busca. Faithfulness baixa $\rightarrow$ problema no LLM/*prompt*.

Extração de Informação (IE)

Definição

Processo de identificar e estruturar automaticamente palavras-chave, tópicos, entidades e relações em texto não estruturado. O resultado transforma um acervo em conhecimento organizado.

Complementar ao RAG

Extração ajuda a **compreender** o acervo como um todo; RAG ajuda a **responder perguntas pontuais** sobre ele.

Extração de Informação (IE)

Definição

Processo de identificar e estruturar automaticamente palavras-chave, tópicos, entidades e relações em texto não estruturado. O resultado transforma um acervo em conhecimento organizado.

Complementar ao RAG

Extração ajuda a **compreender** o acervo como um todo; RAG ajuda a **responder perguntas pontuais** sobre ele.

Extração de Palavras-chave (*Keyword Extraction*)

Método	Funcionamento	Característica
TF-IDF	Frequência no doc. penalizada pelo corpus	*Baseline* estatístico
RAKE (2010)	Grafo de co-ocorrência de palavras	Rápido, sem treino
YAKE (2020)	Estatísticas posicionais e de contexto	Independe de idioma/corpus
KeyBERT (2020)	Similaridade de *embedding* (BERT)	Relevância semântica

Qual usar?

Triagem rápida: RAKE/YAKE. Relevância semântica (reaproveitando o *embedding* do RAG): KeyBERT.

Extração de Palavras-chave (*Keyword Extraction*)

Método	Funcionamento	Característica
TF-IDF	Frequência no doc. penalizada pelo corpus	*Baseline* estatístico
RAKE (2010)	Grafo de co-ocorrência de palavras	Rápido, sem treino
YAKE (2020)	Estatísticas posicionais e de contexto	Independe de idioma/corpus
KeyBERT (2020)	Similaridade de *embedding* (BERT)	Relevância semântica

Qual usar?

Triagem rápida: RAKE/YAKE. Relevância semântica (reaproveitando o *embedding* do RAG): KeyBERT.

Modelagem de Tópicos (*Topic Modeling*)

Definição

Descobre, de forma não supervisionada, os temas latentes de uma coleção de N documentos.

- **LDA** (Blei et al., 2003): tópicos como distribuições sobre palavras; documentos como mistura de tópicos.
- **BERTopic** (Grootendorst, 2022): *embeddings* + UMAP + HDBSCAN + c-TF-IDF. Pode produzir tópicos mais interpretáveis em corpora semânticos, mas precisa ser avaliado no domínio.

Aplicação

"Quais subtemas aparecem nos N artigos sobre evasão escolar? (fatores socioeconômicos, algoritmos preditivos, EAD, avaliação de modelos...)"

Modelagem de Tópicos (*Topic Modeling*)

Definição

Descobre, de forma não supervisionada, os temas latentes de uma coleção de N documentos.

- **LDA** (Blei et al., 2003): tópicos como distribuições sobre palavras; documentos como mistura de tópicos.
- **BERTopic** (Grootendorst, 2022): *embeddings* + UMAP + HDBSCAN + c-TF-IDF. Pode produzir tópicos mais interpretáveis em corpora semânticos, mas precisa ser avaliado no domínio.

Aplicação

"Quais subtemas aparecem nos N artigos sobre evasão escolar? (fatores socioeconômicos, algoritmos preditivos, EAD, avaliação de modelos...)"

Modelagem de Tópicos (*Topic Modeling*)

Definição

Descobre, de forma não supervisionada, os temas latentes de uma coleção de N documentos.

- **LDA** (Blei et al., 2003): tópicos como distribuições sobre palavras; documentos como mistura de tópicos.
- **BERTopic** (Grootendorst, 2022): *embeddings* + UMAP + HDBSCAN + c-TF-IDF. Pode produzir tópicos mais interpretáveis em corpora semânticos, mas precisa ser avaliado no domínio.

Aplicação

"Quais subtemas aparecem nos N artigos sobre evasão escolar? (fatores socioeconômicos, algoritmos preditivos, EAD, avaliação de modelos...)"

Análise de Tendências (*Trend Analysis*)

Combinando Tópicos + Metadados Temporais

1. Extrair tópico dominante de cada documento
2. Agrupar documentos por ano de publicação
3. Calcular frequência relativa do tópico por período
4. Plotar série temporal: tópicos emergentes vs. em declínio

Atenção

Tendência relevante = frequência crescente + relevância sustentada, não apenas contagem pontual.

Análise de Tendências (*Trend Analysis*)

Combinando Tópicos + Metadados Temporais

1. Extrair tópico dominante de cada documento
2. Agrupar documentos por ano de publicação
3. Calcular frequência relativa do tópico por período
4. Plotar série temporal: tópicos emergentes vs. em declínio

Atenção

Tendência relevante = frequência crescente + relevância sustentada, não apenas contagem pontual.

Extração de Relações e Grafos de Conhecimento

NER e Relation Extraction (RE)

NER: identifica entidades como algoritmos, *datasets* e métricas. **RE:** conecta pares de entidades por relações, por exemplo, *Random Forest* utilizado em predição de evasão escolar.

Abordagem Clássica

Pipeline NER (spaCy) + classificador de relações.

Abordagem via LLM

Um *prompt* pode retornar entidades e relações em JSON, mas a saída exige validação.

⚠ Entidades/relações extraídas por LLM também podem ser alucinadas. Valide contra o texto de origem. O grafo resultante é o insumo do **GraphRAG**.

Extração de Relações e Grafos de Conhecimento

NER e Relation Extraction (RE)

NER: identifica entidades como algoritmos, *datasets* e métricas. **RE:** conecta pares de entidades por relações, por exemplo, *Random Forest* utilizado em predição de evasão escolar.

Abordagem Clássica

Pipeline NER (spaCy) + classificador de relações.

Abordagem via LLM

Um *prompt* pode retornar entidades e relações em JSON, mas a saída exige validação.

⚠ Entidades/relações extraídas por LLM também podem ser alucinadas. Valide contra o texto de origem. O grafo resultante é o insumo do **GraphRAG**.

Extração de Relações e Grafos de Conhecimento

NER e Relation Extraction (RE)

NER: identifica entidades como algoritmos, *datasets* e métricas. **RE:** conecta pares de entidades por relações, por exemplo, *Random Forest* utilizado em predição de evasão escolar.

Abordagem Clássica

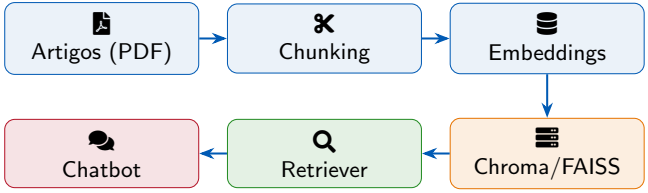
Pipeline NER (spaCy) + classificador de relações.

Abordagem via LLM

Um *prompt* pode retornar entidades e relações em JSON, mas a saída exige validação.

⚠ Entidades/relações extraídas por LLM também podem ser alucinadas. Valide contra o texto de origem. O grafo resultante é o insumo do **GraphRAG**.

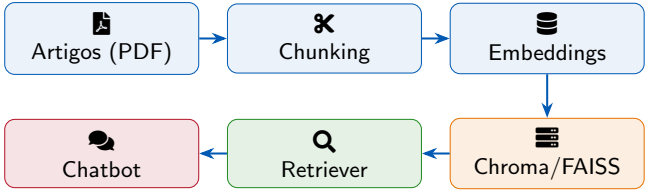
Chatbot RAG sobre um Acervo de Artigos Científicos



Etapas (implementadas no Colab)

1. Carregamento → 2. Extração exploratória (palavras-chave/tópicos) → 3. Chunking → 4. Embedding + Indexação → 5. Retriever (semântico/MMR) → 6. RetrievalQA → 7. Interface conversacional → 8. Avaliação (RAGAS)

Chatbot RAG sobre um Acervo de Artigos Científicos



Etapas (implementadas no Colab)

1. Carregamento → 2. Extração exploratória (palavras-chave/tópicos) → 3. Chunking → 4. Embedding + Indexação → 5. Retriever (semântico/MMR) → 6. RetrievalQA → 7. Interface conversacional → 8. Avaliação (RAGAS)

Limitações a Considerar no Projeto

- O chatbot só responde bem sobre o que está no acervo indexado
- Perguntas multi-documento podem exigir Map-Reduce ou GraphRAG
- `chunk_size` e k do *retriever* são hiperparâmetros a ajustar empiricamente

→ Implementação completa e código no notebook Colab deste módulo.

Segurança e Governança em RAG

Riscos

- Documento malicioso pode tentar alterar instruções do LLM
- Recuperar um trecho não autoriza expor dados pessoais ou sigilosos
- Citação aumenta auditabilidade, mas não prova que a conclusão está correta

Controles

- Controle de acesso antes da recuperação
- Separar instruções do sistema, consulta e documentos
- Registrar fontes e avaliar respostas antes da implantação

Reflexão

Se um estudante só pode ler parte do acervo, em qual etapa essa permissão deve ser aplicada?

Acesso responsável ao acervo



Figura: Em um sistema RAG, a recuperação deve respeitar as permissões de acesso ao acervo.

Reflexão

Por que é insuficiente verificar a permissão do usuário apenas depois que o documento já foi recuperado?

Estado da Arte: Self-RAG e Corrective RAG

Self-RAG (Asai et al., 2023)

Treina o modelo para emitir *tokens* de reflexão que decidem quando recuperar, se os documentos são relevantes e se a resposta é sustentada pelo contexto.

Corrective RAG (CRAG, Yan et al., 2024)

Um avaliador classifica a qualidade dos documentos recuperados e pode disparar recuperação complementar quando a confiança é baixa.

Estado da Arte: Self-RAG e Corrective RAG

Self-RAG (Asai et al., 2023)

Treina o modelo para emitir *tokens* de reflexão que decidem quando recuperar, se os documentos são relevantes e se a resposta é sustentada pelo contexto.

Corrective RAG (CRAG, Yan et al., 2024)

Um avaliador classifica a qualidade dos documentos recuperados e pode disparar recuperação complementar quando a confiança é baixa.

Estado da Arte: GraphRAG e RAG Agêntico

GraphRAG (Microsoft Research, 2024)

Constrói um grafo de entidades a partir dos documentos e pode sumarizar comunidades. É útil para perguntas globais ou com múltiplos saltos, desde que a extração do grafo seja confiável.

RAG Agêntico (*Agentic RAG*)

Um agente decide quantas recuperações executar, quais ferramentas consultar e quando encerrar. A flexibilidade vem acompanhada de mais custo, latência e necessidade de avaliação.

→ Material Didático e Colab trazem o pipeline completo do chatbot RAG

Estado da Arte: GraphRAG e RAG Agêntico

GraphRAG (Microsoft Research, 2024)

Constrói um grafo de entidades a partir dos documentos e pode sumarizar comunidades. É útil para perguntas globais ou com múltiplos saltos, desde que a extração do grafo seja confiável.

RAG Agêntico (*Agentic RAG*)

Um agente decide quantas recuperações executar, quais ferramentas consultar e quando encerrar. A flexibilidade vem acompanhada de mais custo, latência e necessidade de avaliação.

→ Material Didático e Colab trazem o pipeline completo do chatbot RAG

Referências Bibliográficas

- Lewis, P. et al. *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. NeurIPS, 2020.
- Gao, Y. et al. *Retrieval-Augmented Generation for Large Language Models: A Survey*. arXiv:2312.10997, 2024.
- Asai, A. et al. *Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection*. arXiv:2310.11511, 2023.
- Yan, S.-Q. et al. *Corrective Retrieval Augmented Generation*. arXiv:2401.15884, 2024.
- Edge, D. et al. *From Local to Global: A Graph RAG Approach*. Microsoft Research, arXiv:2404.16130, 2024.
- Carbonell, J.; Goldstein, J. *The Use of MMR, Diversity-Based Reranking*. SIGIR, 1998.
- Blei, D. M. et al. *Latent Dirichlet Allocation*. JMLR, 2003.
- Grootendorst, M. *BERTopic: Neural Topic Modeling with a Class-based TF-IDF Procedure*. arXiv:2203.05794, 2022.
- **Material Didático Módulo 7** e Notebook Colab disponíveis no repositório da disciplina.